بوت‌کمپ Agentic AI کوئرا · پروژهٔ نهایی

# دستیار پشتیبانی فنی Streamlit

از گزارش خطا تا پاسخ، پرسش یا ارجاع: داده، پایپ‌لاین، ارزیابی و اصلاح

| | | | | |
|---|---|---|---|---|
| dev | ۵٫۷٪ ← ۷۳٫۲٪<br>بخش‌های gold در پرامپت | ۱۱ · ۱۲ · ۰۵<br>تصمیم درست از ۱۵: Baseline · gpt-5.4-mini · gpt-5-mini | ۱۰ · ۰۹ · —<br>«قبول» داور: Baseline · gpt-5.4-mini · gpt-5-mini | ۲۰٪ ← ۱۰۰٪<br>پاسخ‌های مستند به gold |
| test | ۰٪ ← ۴۵٫۰٪<br>بخش‌های gold در پرامپت | ۸ · ۶ · ۰۶<br>تصمیم درست از ۱۵: Baseline · gpt-5.4-mini · gpt-5-mini | ۶ · ۵ · ۰۱<br>«قبول» داور: Baseline · gpt-5.4-mini · gpt-5-mini | ۰٪ ← ۱۰۰٪<br>پاسخ‌های مستند به gold |

supportdesk · ۲۶ مهر ۱۴۰۵

# مجموعه داده

دامنه را به وضعیت نشست محدود کردیم: حافظهٔ موقت همان کاربر در همان باز کردن برنامه، و تعامل آن با ویجت، کال‌بک، فرم و چندصفحه.

### ایشو

- گزارش مشکل در گیت‌هاب

### کامنت

- بحث ذیل همان گزارش

### مستند

- راهنمای رسمی، نسخهٔ pinned

### یادداشت انتشار

- تغییر هر نسخه، بندبه‌بند

- منابع عمومی پاسخ آماده نیستند؛ باید گرد آورد، پاک‌سازی کرد و نسخهٔ ثابت ساخت.
- داده یک‌بار با GitHub API ذخیره شد؛ هنگام ارزیابی دوباره از وب خوانده نمی‌شود.
- ۱۵ پروندهٔ توسعه و ۱۵ آزمون بیرون جست‌وجو می‌مانند؛ کامنت همان ایشوها هم نمی‌آید.

# از آرشیو خام تا ۵۴۰ رکورد

کاهش شمار سخت‌گیری موضوع است، نه از دست رفتن داده. ارزیابی از اول جدا شد تا نشت نکند.

**۲۲۰ + ۵۰۰**
متمرکز + همکار

←

**۶۹۰**
یکتا

←

**۱۶۴**
نسخهٔ ۲

←

**۱۲۶**
ایشو

| ۱۲۶ | ۲۱۴ | ۵۴ | ۱۱۱ | ۳۵ |
|---|---|---|---|---|
| ایشو | کامنت | مستند | بند انتشار | مرجع لینک‌شده |

جمع **۵۴۰ رکورد** است، نه تکه. مستند در ادغام حدود ۷۰ شکل ذخیره‌شده داشت؛ برای جست‌وجو ۲۱ صفحهٔ یکتا ماند و بعد با لینک فنی به ۵۴ رسید. فیلتر تاریخ فقط برای تاریخ باز شدن ایشو است: ۱ ژوئیه ۲۰۲۱ تا ۶ اکتبر ۲۰۲۶.

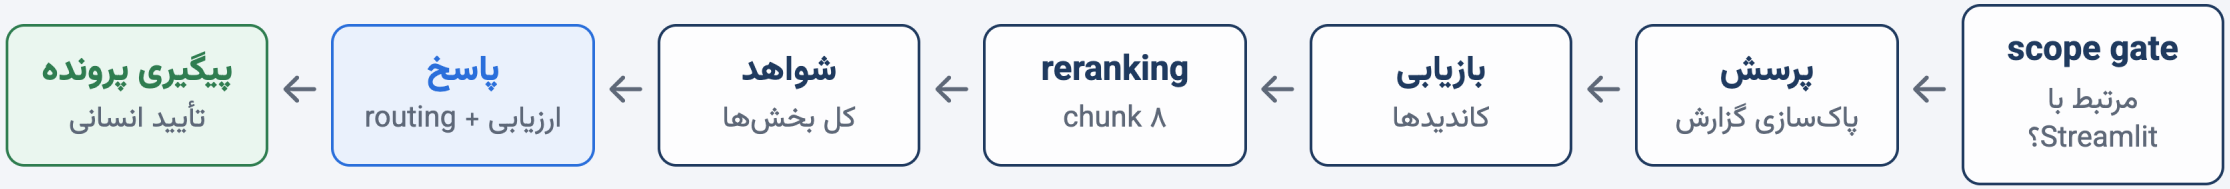
# چهار لایه؛ یک فیلتر نبود

| نسخه | کار | تعداد |
|---|---|---|
| ۳ | چه چیز اصلاً وارد شود: پیام خالی، پیشنهاد بدون تأیید رسمی، تصویر، اسم غلط رابط، مستند نامربوط | ۴۷۲ |
| ۴ | شلوغی قالب از متن کم شد؛ کد داخل حصار دست نخورد | همان ۴۷۲ |
| ۵ | لینک فنی دنبال شد و محتوایش هم اضافه شد؛ متن قبلی عوض نشد | ۵۴۰ |
| ۶ | متن ثابت ماند؛ پروندهٔ ارزیابی با همان حروف هم‌تراز شد | همان ۵۴۰ متن |

از نسخهٔ ۵ به بعد خود متن منبع عوض نشده است. نسخهٔ ۶ تکه و امبد نساخت. نقل‌قول مرجع دستی در ۱۵ اکتبر ۲۰۲۶ روی همان کورپس علامت خورد؛ مجموعهٔ جدید نیست.

سامانه در یک نگاه

# گراف اول LangGraph: از گزارش تا اقدام




## چرا LangGraph

- هر مرحله یک node جدا: هر آزمایش فقط یک مرحله را عوض می‌کند
- state صریح میان مرحله‌ها: خروجی هر مرحله دیده و ثبت می‌شود
- توقف برای تأیید انسانی (interrupt) و ادامه از همان نقطه (checkpoint)
- همان گراف در CLI، ارزیابی و رابط وب

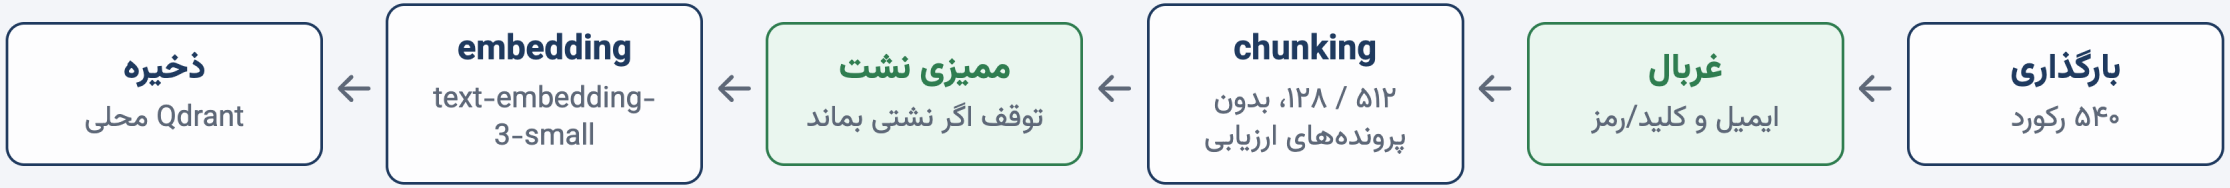
## مسئلهٔ ۲ جدا نیست

- پیگیری پرونده ادامهٔ همان گراف است: پرسش یا ارجاع، پرونده را به نوبت بعد یا به نگه‌دارنده می‌برد
- پیش از هر انتشار، توقف برای تأیید انسانی
- پیام بعدی کاربر از همان state ادامه پیدا می‌کند

## زیرساخت مشترک

- درگاه واحد مدل: کش، دفتر هزینه، سقف ۵ دلار
- سه حالت: offline، replay، live
- ۱۰۰ پایپ‌لاین ثبت‌شده، حدود ۷۰۰ آزمون خودکار

# گراف دوم: LangGraph ساخت index، با غربال و ممیزی نشت




## غربال و ممیزی نشت

**غربال:** هر رکورد برای دادهٔ شخصی (ایمیل) و رمز یا کلید API بررسی می‌شود؛ اگر پیدا شود، ساخت index متوقف می‌شود (متن ویرایش نمی‌شود)

**هنگام chunking:** ایشوی پرونده‌های ارزیابی و کامنت‌هایشان کنار می‌روند

**ممیزی نشت:** اگر chunkی هنوز با پرونده‌ای هم‌پوشانی داشته باشد، ساخت متوقف می‌شود

## چرا Qdrant

- محلی، بدون سرویس خارجی: قابل بازتولید
- فیلتر روی نوع منبع و تاریخ
- جست‌وجوی cosine سریع، ذخیره روی دیسک

## آزموده و بی‌اثر

- embedding بزرگ‌تر (3-large): ۵۴٫۴٪ در برابر ۶۱٫۸٪
- ترکیب دو مدل embedding: ۵۸٫۵٪ تا ۵۹٫۶٪ در برابر ۶۱٫۸٪

Baseline و advanced هر دو همین index را دارند؛ advanced بانک پرسش‌های doc2query را هم یک‌بار می‌سازد (اسلاید ۱۳).

Baseline

# Baseline، ساده‌ترین سامانهٔ قابل دفاع، و نتایجش

**گزارش**
متن خام
←
**جست‌وجوی برداری**
۶ chunk نزدیک‌تر
←
**یک فراخوانی**
gpt-4o-mini
←
**پاسخ، پرسش یا ارجاع**
ارجاع در کد اگر اطمینان پایین

| معیار | dev (۱۵ پرونده) | test (۱۵ پرونده) |
|---|---|---|
| بخش‌های gold در پرامپت | ۵٫۷٪ | ۰٪ |
| پرونده‌های دارای دست‌کم یک بخش gold | ۱۳٫۳٪ | ۰٪ |
| تصمیم درست (پاسخ · پرسش · ارجاع) | ۵ از ۱۵ (۱ · ۲ · ۲) | ۶ از ۱۵ (۲ · ۲ · ۲) |
| پاسخ‌های مستند به gold | ۲۰٪ | ۰٪ |
| داوری مستقل: قبول / نسبی / رد | — | ۱ / ۲ / ۱۲ |
| هزینه و زمان هر پرونده | ~$ ۰٫۰۰۰۸ · ۵۰ ثانیه | ~$ ۰٫۰۰۰۷ |

طراحی نهایی

# advanced، از گزارش تا اقدام

بازیابی

scope gate
gpt-4o-mini · ~$ ۰٫۰۰۰۱
←
پاک‌سازی گزارش
کد · $ ۰
←
جست‌وجو
۱۵ کاندید · embedding
←
doc2query
+ ۱۵ بخش · $ ۰
←
reranking
با gpt-4o-mini ·
~$ ۰٫۰۰۰۵ embedding
←
تکمیل بخش
کد · $ ۰

پاسخ و پیگیری

یادداشت نسخه
کد · $ ۰
←
ارزیابی ساختاریافته
gpt-5.4-mini · ~$ ۰٫۰۲۳۷
←
routing در پایتون
کد · $ ۰
←
پرسش کامل
کد · $ ۰
←
پیگیری پرونده
تأیید انسانی · $ ۰

**~$ ۰٫۰۲۴**
هزینهٔ کل هر پرونده، با ۳ فراخوانی مدل

**۷۳٫۲٪ · ۴۵٫۰٪**
بخش‌های gold در پرامپت: dev · test

**۱۲ · ۶ از ۱۵**
تصمیم درست: test · dev

**۱۰۰٪ · ۱۰۰٪**
پاسخ‌های مستند: test · dev

**۹ · ۵ از ۱۵**
«قبول» داور مستقل: test · dev

بهبود · scope gate

# گزارش‌های نامربوط، پیش از هر هزینه کنار می‌روند

### چه می‌کند

- یک فراخوانی کوچک gpt-4o-mini پیش از بازیابی: آیا گزارش دربارهٔ Streamlit است؟
- نامربوط: پاسخ ثابت، بدون جست‌وجو و بدون مدل پاسخ
- مرتبط: ادامهٔ پایپ‌لاین

### چرا

- جلوگیری از پاسخ‌های بی‌پایه به پرسش‌های عمومی Python یا فریم‌ورک‌های دیگر
- صرفه‌جویی در هزینهٔ بازیابی و مدل پاسخ

| مدل | دقت | رد اشتباه گزارش مرتبط | پذیرش اشتباه |
|---|---|---|---|
| gpt-4o-mini | ۱۰۰٪ | ۰ | ۰ |
| gpt-4.1-nano | ۹۹٫۲٪ | ۰ | ۱ |

محک ۱۲۰ گزارش: ۶۰ مرتبط و ۶۰ نامربوط (Python عمومی، فریم‌ورک‌های دیگر، کد بی‌توضیح، نسخه‌های قدیمی). هزینهٔ کل ~۰٫۰۱ دلار.

**روی ۱۵ پروندهٔ test، هر ۱۵ گزارش واقعی را عبور داد.**

# روش‌ها، و اینکه هر بخش gold چقدر در یک chunk جا می‌شود

### روش‌ها

**پنجرهٔ ثابت (fixed):** هر ۵۱۲ توکن یک chunk، با ۱۲۸ توکن همپوشانی

**ساختاری (structure):** برش در هر عنوان؛ chunkهای کوچک، به اندازهٔ یک بخش

**ساختاری با سقف توکن (token_structure):** برش در عنوان‌ها، بخش‌های کوچک کنار هم تا سقف توکن

**قاعدهٔ LangChain:** تقسیم Markdown بر اساس عنوان‌ها

**با مدل زبانی:** مدل مرز chunkها را انتخاب می‌کند

| روش | chunk | بخش gold کامل در یک chunk | دست‌کم ۸۰٪ در یک chunk | سقف با ۶ chunk |
|---|---|---|---|---|
| fixed | ۶۳۶ | ۸۰ (۹۹٪) | ۸۱ (۱۰۰٪) | ۹۸٪ |
| structure | ۱٬۱۸۶ | ۷۵ (۹۳٪) | ۷۶ (۹۴٪) | ۸۹٪ |
| token_structure | ۶۵۴ | ۸۰ (۹۹٪) | ۸۰ (۹۹٪) | ۹۶٪ |

۸۱ بخش gold کوتاه‌اند: میانه ۹۲ توکن، بلندترین ۲۵۳. «سقف با ۶ chunk» یعنی بیشترین بخش gold که شش chunk کاملاً درست‌انتخاب‌شده می‌توانند بیاورند.

**نتیجه: chunking گلوگاه نیست؛ با fixed هر بخش gold در یک chunk جا می‌شود. فاصلهٔ ۹۸٪ تا ۷۳٪ از جست‌وجو و reranking است.**

# در پایپ‌لاین: پنجرهٔ ثابت، و تکمیل بخش

### تکمیل بخش یعنی چه

**۵+ تا ۸+٪**

- پس از reranking، هر chunk مستندات که انتخاب شد تا **کل بخش‌هایی** که در آن‌هاست گسترش می‌یابد (حداکثر ۹۰۰ توکن)
- chunkهای هم‌پوشان یک صفحه یکی می‌شوند
- چرا: بخش gold اغلب در زیربخش همسایهٔ chunk انتخاب‌شده است

| روش chunking (همه با reranking و ۸ chunk) | بخش‌های gold پوشش‌داده‌شده | بخش‌های gold در پرامپت |
|---|---|---|
| fixed + تکمیل بخش (advanced) | ۸۱ از ۸۱ (٪۱۰۰) | ۷۰٫۱٪ |
| token_structure | ۸۰ از ۸۱ (٪۹۹) | ۵۸٫۲٪ |
| token_structure + chunkهای همسایه | ۸۰ از ۸۱ (٪۹۹) | ۶۵٫۶٪ |
| قاعدهٔ LangChain | — | ۴۴٫۶٪ |
| قاعدهٔ LangChain + chunkهای همسایه | — | ۵۲٫۹٪ |
| fixed + تکمیل بخش با برش | ۸۱ از ۸۱ (٪۱۰۰) | ۶۴٫۳٪، یک پرونده بی‌شاهد |

پوشش‌داده‌شده: بخش gold دست‌کم ۸۰٪ در یک chunk. برای قاعدهٔ LangChain سنجیده نشد. پوشش تقریباً کامل است؛ تفاوت ستون آخر از انتخاب chunkهاست.

chunkهای کوچک ساختاری صفحهٔ درست را پیدا می‌کنند، اما متن کمتری از آن می‌آورند. روش برندهٔ آزمایش کلیدواژه‌ای تیم داده هم در پایپ‌لاین کامل، با جست‌وجوی معنایی و reranking، به پنجرهٔ ثابت نرسید.

بهبود · پرسش جست‌وجو

# گزارش پاک‌شده، تنها پرسش جست‌وجوست

## Baseline

• متن خام گزارش، با قالب GitHub: چک‌لیست، اطلاعات اشکال‌زدایی، پرسش‌های ثابت

## advanced

**پاک‌سازی:** قالب حذف؛ عنوان، کد، فراخوانی‌های .st* و پیام خطا می‌مانند

• به‌تنهایی: بخش‌های gold ٪۵٫۷ ← ٪۲۷٫۱

## آزموده و بی‌اثر

**تقسیم به جمله‌ها:** هر جملهٔ گزارش جداگانه جست‌وجو و نتایج ادغام شد. **نتیجه:** ٪۳۹٫۹ در برابر ٪۳۹٫۶، بی‌تفاوت.

**تقسیم با مدل زبانی:** مدل گزارش را به بخش‌های مستقل تقسیم کرد و هر بخش جست‌وجو شد. **نتیجه:** ٪۱۲٫۳.

**پرسش‌های مفهومی:** مدل یک تا سه پرسش دربارهٔ سازوکارهای Streamlit درگیر نوشت و هر کدام جست‌وجو شد (سه نسخه پرامپت). **نتیجه:** ۴۸٪ تا ۶۲٪ در برابر ٪۶۱٫۸، با یک فراخوانی بیشتر.

**جست‌وجوی جدا برای عنوان یا کد:** علاوه بر کل گزارش، یک جست‌وجو فقط با عنوان، و یکی فقط با نام‌های کد و متن خطا؛ نتایج ادغام شد، با این فرض که این بخش‌ها نشانهٔ دقیق‌تری از سازوکارند. **نتیجه:** نتیجهٔ مختلط، بدون بهبود پایدار.

# پرسش‌هایی به زبان کاربر، برای هر بخش مستندات

### چرا

• کاربر علامت را توصیف می‌کند، نه سازوکار را: «مقدار ویجت بعد از رفتن به صفحهٔ دیگر پاک می‌شود»، در حالی که بخش مستندات عنوان «Statefulness of widgets» دارد

• این شکاف واژگانی باعث می‌شد جست‌وجو بعضی صفحه‌های درست را هرگز پیدا نکند

### هزینه

• یک‌بار، حدود ۰٫۰۲ دلار برای ۱۴۶ بخش؛ با هر تغییر مستندات از نو

### مراحل

**۱.** برای هر یک از ۱۴۶ بخش مستندات، gpt-4o-mini پنج پرسش می‌نویسد که کاربری با آن مشکل ممکن است بپرسد

**۲.** ۷۳۰ پرسش یک‌بار embedding و ذخیره می‌شوند

**۳.** هنگام جست‌وجو، گزارش با پرسش‌ها هم مقایسه می‌شود

**۴.** ۱۵ chunk بخشی که پرسش‌هایشان نزدیک‌ترند به کاندیدها اضافه می‌شود

**۵.** reranker از میان همه انتخاب می‌کند

**dev: بخش‌های gold ۷۰٫۱٪ ← ۷۳٫۲٪ · بخش‌های روی صفحه‌های هرگز پیدانشده ۱۸ ← ۴ · test: ۵۲٫۶٪ ← ۴۵٫۰٪ (اسلاید ۱۷)**

بهبود · جست‌وجو

# جای ثابت برای مستندات

## Baseline

- جست‌وجوی برداری، ۶ نتیجهٔ نزدیک‌تر
- ایشوهای مشابه همهٔ جاها را پر می‌کنند

## advanced

- ۱۵ کاندید، که ۱۰ جای آن برای مستندات کنار گذاشته می‌شود
- به‌اضافهٔ کاندیدهای doc2query
- همراه با پاک‌سازی: ۵٫۷٪ ← ۳۹٫۶٪

## آزموده و بی‌اثر

**جست‌وجوی ترکیبی با BM25:** جست‌وجوی کلیدواژه‌ای با جست‌وجوی برداری ادغام شد (RRF)، تا نام‌های دقیق API و متن خطا هم پیدا شوند. **نتیجه:** پیش از reranking حدود ۴٪ بهتر؛ پس از reranking حدود ۱۱٪ بدتر.

**خوشه‌ها و routing موضوعی:** بخش‌های مستندات خوشه‌بندی یا برچسب موضوعی شدند و جست‌وجو به موضوع گزارش محدود یا تقویت شد. **نتیجه:** ناپایدار: از ۳۴٪ تا ۷۱٫۷٪ در برابر ۷۰٫۱٪؛ حالت محدودکننده پرونده‌ها را بی‌شاهد کرد.

**کاندیدهای بیشتر:** ۲۰ کاندید به‌جای ۱۵. **نتیجه:** بی‌تفاوت.

بهبود · reranking

# یک فراخوانی reranker، ۸ chunk، کل بخش‌ها

## advanced

- gpt-4o-mini همهٔ کاندیدها را مرتب می‌کند؛ از هر کاندید ۴۰۰ نویسهٔ منطبق‌تر با گزارش را می‌بیند
- ۸ chunk نگه داشته می‌شود، دست‌کم ۵ از مستندات؛ سپس تکمیل بخش؛ سقف ۴٬۳۰۰ توکن
- reranking: ۳۹٫۶٪ ← ۵۹٫۱٪ · ۸ chunk: ۶۱٫۸٪ ← ۷۰٫۱٪
- بدون reranker (آزمون کنترل): ۷۰٫۱٪ ← ۶۴٫۳٪

## آزموده و بی‌اثر

**reranker قوی‌تر:** gpt-4.1-mini به‌جای gpt-4o-mini. **نتیجه:** همان بخش‌های gold، ترتیب بدتر.

**پرامپت توضیحی:** از reranker خواسته شد متنی را جلو بیاورد که علت یا راه‌حل را توضیح می‌دهد، حتی اگر واژه‌های گزارش را نداشته باشد. **نتیجه:** در حد نوسان، ترتیب بدتر.

**دو رتبه‌بندی ادغام‌شده:** یک فراخوانی با پرامپت عادی (مرتبط‌بودن با موضوع گزارش) و یکی با پرامپت توضیحی؛ دو ترتیب ادغام شد. **نتیجه:** بدون سود پایدار، با دو فراخوانی.

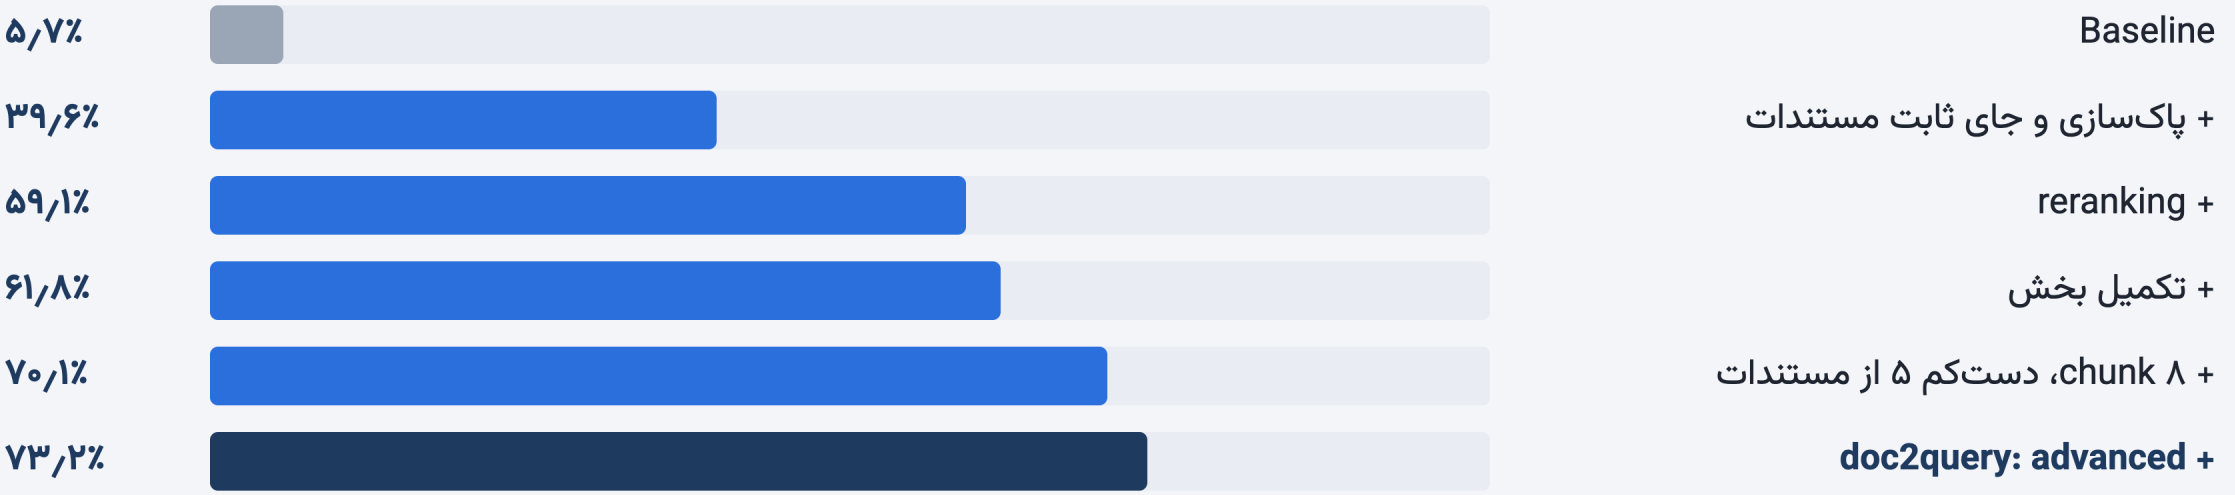
**ترکیب با رتبهٔ جست‌وجو:** میانگین رتبهٔ reranker و رتبهٔ جست‌وجوی برداری. **نتیجه:** ۱٪ تا ۲۱٪ بدتر.

**آگاه از نسخه:** نسخهٔ کاربر و نسخهٔ هر کاندید به reranker داده شد، با قاعدهٔ «منبع مناسب نسخهٔ کاربر را ترجیح بده». **نتیجه:** ۷۳٫۲٪ ← ۷۱٫۱٪؛ gold در رتبهٔ ۱: ۸۰٪ ← ۵۳٪؛ تصمیم‌ها بی‌تغییر.

**یادداشت‌های انتشار جدیدتر:** دو یادداشت انتشارِ جدیدتر از نسخهٔ کاربر به کاندیدها اضافه شد. **نتیجه:** ۷۳٫۲٪ ← ۶۸٫۲٪؛ مستندات لینک‌شده را بیرون راند.

نتایج بازیابی · dev

# اثر هر تغییر: بخش‌های gold در پرامپت




هر پله یک تغییر نسبت به پلهٔ قبل؛ ۱۵ پروندهٔ dev و ۸۱ بخش .gold بخش gold یعنی بخشی از منبع که دست‌کم ۸۰٪ متنش به مدل رسیده است.

# هر بخش gold کجا گم می‌شود؟




doc2query صفحه‌های پیدانشده را کم کرد (dev ۱۸ ← ۴، test ۱۷ ← ۱۰)، اما reranker بیشتر حذف کرد (۶ ← ۱۳، ۴ ← ۱۷). خالص: dev +۴ بخش، test -۴ بخش.

# همهٔ معیارها، روی هر دو مجموعه

| معیار | Baseline dev | advanced dev | Baseline test | بدون doc2query test | advanced test |
|---|---|---|---|---|---|
| بخش‌های gold در پرامپت (passage) | ۵٫۷٪ | ۷۳٫۲٪ | ۰٪ | ۵۲٫۶٪ | ۴۵٫۰٪ |
| پرونده‌های دارای دست‌کم یک بخش gold | ۱۳٫۳٪ | ۱۰۰٪ | ۰٪ | ۹۳٫۳٪ | ۹۳٫۳٪ |
| بخش gold در رتبهٔ ۱ | ۶٫۷٪ | ۸۰٫۰٪ | ۰٪ | ۴۶٫۷٪ | ۳۳٫۳٪ |
| MRR سطح بخش | ۰٫۰۸۰ | ۰٫۸۸۹ | ۰ | ۰٫۶۲۴ | ۰٫۵۷۶ |
| صفحه‌های gold در پرامپت (document) | ۴٫۴٪ | ۷۳٫۳٪ | ۰٪ | ۵۹٫۴٪ | ۶۱٫۷٪ |
| MRR سطح صفحه | — | ۰٫۸۸۹ | ۰ | ۰٫۶۸۰ | ۰٫۷۳۳ |

passage: بخش مشخص و برچسب‌خورده؛ document: کل منبع (صفحه، ایشو، کامنت). روی test، doc2query صفحه‌های درست را بالاتر آورد اما بخش‌های gold کمتری رساند؛ Baseline هیچ شاهد gold پیدا نکرد.

# مدل ارزیابی می‌نویسد، پایتون تصمیم می‌گیرد

### Baseline

- یک فراخوانی gpt-4o-mini پاسخ را مستقیم می‌نویسد

### advanced

- gpt-5.4-mini یک ارزیابی ساختاریافته می‌نویسد: نیاز اصلی، واقعیت‌ها با شاهد، کمبودهای اطلاعاتی، نیاز به بررسی داخلی
- یک قاعدهٔ پایتون از روی آن پاسخ، پرسش یا ارجاع را انتخاب می‌کند
- پرامپت: نسخهٔ v2، بدون تغییر

### آزموده و بی‌اثر

**پاسخ‌گوی ساده روی شواهد بهتر:** همان یک فراخوانی Baseline، با شواهد advanced. **نتیجه:** ۵ تا ۷ از ۱۵؛ تقریباً همه را پاسخ می‌دهد و هرگز ارجاع نمی‌دهد.

**انتخاب اقدام توسط خود مدل:** مدل با یک پرامپت سیاست، خودش پاسخ، پرسش یا ارجاع را انتخاب می‌کند. **نتیجه:** ۱۰ از ۱۵.

**قاعدهٔ ارجاع در پرامپت (v3):** ثبت بررسی داخلی وقتی بازتولید کامل است. **نتیجه:** پاسخ‌های درست به پرسش تبدیل شد؛ ارجاعی رخ نداد.

**سه قاعدهٔ پیشنهادی داور (v4):** اطلاعاتِ گفته‌شده کمبود نیست؛ ارجاع با کنترل‌های کامل؛ سقف طول پاسخ. **نتیجه:** تصمیم‌ها بی‌تغییر؛ طول پاسخ ۱۷۵ ← ۴۷ واژه.

# از گزارش مشکل تا اقدام پشتیبانی

**هدف محصول: کاربر بداند الان چه کاری باید انجام دهد.**

گزارش کاربر | شواهد بازیابی | سابقه مکالمه

این سه ورودی، زمینهٔ تصمیم را می‌سازند.

**خروجی: پاسخ مستند، یک سؤال مفید یا پیشنهاد بررسی انسانی**

هدف

# داخل این بخش چه اتفاقی می‌افتد؟

**ورودی: گزارش + چانک‌های واقعی بازیابی + تاریخچه**

آماده‌سازی ← ارزیابی مدل ← بررسی خروجی ← تصمیم کنترلر

مدل: نیاز اصلی، اطلاعات گمشده، پاسخ پیشنهادی و نیاز به بررسی داخلی

**برنامه: آماده‌سازی، کنترل ارجاع‌ها، انتخاب اقدام و ساخت پیام**

مسیر ← هدف

# چه زمانی جواب، سؤال یا ارجاع؟

## اولویت اول: ضرورت مشخص برای بررسی انسانی

| | |
|---|---|
| **درخواست اطلاعات** | اطلاعات مهم کم است و کاربر می‌تواند آن را روشن کند. |
| **پاسخ مستند** | ابهام مهم باقی نمانده و پاسخ پیشنهادی پشتیبانی می‌شود. |
| **ارجاع** | بررسی داخلی لازم است و سؤال مفید دیگری باقی نمانده. |

# مثال واقعی: یک سؤال، قبل از ارجاع

گزارش: محدودهٔ ویجت ۱ تا ۵ است، اما مقدار ۱۰ پذیرفته می‌شود.




## «از کدام نسخهٔ استریم‌لیت استفاده می‌کنید؟»

ادامهٔ فرضی، پس از دریافت جواب کاربر






# مسیر کار: از خطاهای مدل تا کنترل تصمیم

بررسی شواهد ← آزمایش پرامپت و بازبین ← جداسازی ارزیابی و تصمیم

مشکل‌هایی که دنبال کردیم: پاسخ زودهنگام، ارجاع زودهنگام و حذف اصلاحات لازم

**خروجی مهندسی: هستهٔ قابل اتصال + ابزار تست تعاملی + گزارش‌های قابل بررسی**

حافظهٔ محلی، انتظار برای کاربر، سقف سؤال‌ها و ثبت مصرف

هدف ← مسیر ← تصمیم ← مثال ← بهبود

# نتیجه روی بهترین شواهد و قدم بعدی محصول

## ۱۱ از ۱۵

تطابق تصمیم اولیه با لیبل توسعه؛ کنترل قبلی: ۹ از ۱۵

هر دو اجرا: ۱۵ فراخوانی؛ هزینهٔ تخمینی حدود ۲۲ و ۲۶ سنت

**مرز نتیجه: شواهد منتخب؛ هنوز معیار عملکرد کل سامانه نیست.**

**قدم بعد: بازیابی واقعی + آزمون مستقل تست**

# داور دقیقاً چه می‌بیند و چگونه قضاوت می‌کند

## ورودی: یک پرونده

• گزارش کاربر و **تصمیم ذخیره‌شده** (پاسخ، پرسش یا ارجاع)

• متن دقیق همهٔ شواهدی که مدل دید، و اینکه کدام استناد شد

• ارزیابی مدل، routing و خلاصهٔ نگه‌دارنده

**فایل ارزیاب:** تصمیم‌های قابل قبول، استدلال مرجع، ادعاهای ممنوع، اطلاعات لازم برای پرسش، بخش‌های gold، و مواد «فقط برای داور»

## قواعد داوری

• فایل ارزیاب مرجع است؛ چند پاسخ متفاوت می‌تواند قابل دفاع باشد

• تصمیم ذخیره‌شده داوری می‌شود، نه فقط متن پاسخ

• هر ادعا فقط با متن شواهد همین پرونده پشتیبانی می‌شود، نه با دانش خود داور

• پاسخ‌ندادن خودبه‌خود امن نیست؛ پرسش خوب فقط آنچه لازم است می‌خواهد، نه آنچه کاربر داده

## خروجی (JSON)

• امتیاز ۰ تا ۲ برای: کیفیت شواهد، تصمیم، درستی عملیاتی، پاسخ کاربر و خلاصهٔ نگه‌دارنده

• فهرست ادعاهای بی‌پشتوانه و ممنوع

• تحلیل خطا: نوع، علت محتمل، اصلاح پیشنهادی

• حکم: قبول، نسبی یا رد

**داور: Claude Opus 4.5، از خانواده‌ای جز مدل پاسخ، بیرون از سامانه؛ هر پرونده جداگانه. مواد «فقط برای داور» (کامنت‌ها و یادداشت‌های بعدی) برای تشخیص درستی است، نه جریمهٔ استناد نکردن.**

# داور مستقل، الگوهای خطا، و دو اصلاح

## داوری

- داور: Claude Opus 5.5، بیرون از سامانه و API پروژه
- مرجع: فایل ارزیاب هر پرونده، که سامانه هرگز نمی‌بیند
- الگوهای dev: نسخه بررسی نمی‌شود (۵ پرونده)، پرسش ناقص (۳)، ارجاع ضعیف (۳)، بخش سازوکار بازیابی نشد (۵)

## اصلاح ۱: یادداشت نسخه

- پیش از مدل، روی هر منبع: چه نسخه‌ای را توصیف می‌کند در برابر نسخهٔ کاربر، و چگونه به کار رود
- مثال: «این انتشار از نسخهٔ شما جدیدتر است، پس این تغییر در آن نیست»
- **چگونه:** قاعده‌محور، یک تابع پایتون بدون مدل؛ از نوع، نسخه و تاریخ منبع و نسخهٔ گزارش، اعداد نسخه مقایسه می‌شوند (قدیمی‌تر، جدیدتر، در بازه)
- دو فیلد version_applicability و usage_constraint را پر می‌کند که بستهٔ پاسخ از قبل نشان می‌داد؛ پرامپت تغییر نکرد

## اصلاح ۲: پرسش کامل

- مدل تا سه کمبود و برای هر کدام یک پرسش می‌نوشت، اما فقط پرسش اول به کاربر می‌رسید
- اکنون همه در یک فهرست شماره‌دار می‌روند
- پس از تصمیم، در کد؛ بدون هزینه

**روی dev: تصمیم‌های درست بی‌تغییر (۱۲)؛ ارجاع ۱ ← ۲ و «قبول» داور ۸ ← ۹. اثر روشنِ اصلاح فقط در DEV-4338: خطای «انتشار به‌عنوان علت» از بین رفت؛ دو پرونده بهتر و دو بدتر شد، در حد نوسان. چرا روی test تکرار نشد: اسلاید بعد.**

# چرا الگوها روی test دوباره دیده شد

## مشکل نسخه از کجا می‌آید

• پیکره فقط مستندات امروز (1.65) را دارد؛ گزارش‌ها از 0.84 تا 1.59 هستند

• مدل قاعده‌های امروز را به نسخهٔ قدیمی تعمیم می‌دهد: قاعدهٔ هویت ویجت (1.55) برای گزارشی روی 1.28 (TEST-7649)

• یادداشت انتشار جدیدتر را علت یا راه‌حل می‌گیرد: «در 1.41 درست شده» برای علامتی دیگر (TEST-9841)

## چرا با وجود اصلاح‌ها ماند

• یادداشت نسخه توصیه است، نه اجبار: در TEST-9841 کنار همان منبع نوشته بود «تغییر را نشان می‌دهد، نه علت را»

• اصلاح‌ها از خطاهای dev طراحی شدند؛ بخشی از اثرشان مخصوص همان پرونده‌ها بود

• خطای پرسش در برابر ارجاع ربطی به نسخه ندارد؛ قضاوت مدل است

• ۱۵ پرونده کم، و نوسان اجراها زیاد است

## آزموده و بی‌اثر

**قاعدهٔ ارجاع در پرامپت (v3):** پاسخ‌های درست به پرسش تبدیل شد؛ ارجاعی رخ نداد

**سه قاعدهٔ داور (v4):** تصمیم‌ها بی‌تغییر؛ طول پاسخ ۱۷۵ ← ۴۷ واژه

**reranking آگاه از نسخه:** بخش‌های gold ٪۷۳٫۲ ← ٪۷۱٫۱

**یادداشت‌های انتشار جدیدتر:** ٪۷۳٫۲ ← ٪۶۸٫۲

**جابه‌جایی قاعده‌های routing:** کنار گذاشته شد؛ مدل اصلاً «بررسی داخلی» ثبت نکرده بود

**راه‌حل واقعی: مستندات نسخه‌دار و فیلتر بر اساس نسخهٔ کاربر؛ یا قاعده‌ای در کد که پاسخ مبتنی بر یادداشت انتشار را فقط با تطابق دقیق شمارهٔ issue یا علامت بپذیرد.**

نتایج · dev

# تصمیم، استناد و داوری روی ۱۵ پروندهٔ dev

| | Baseline | gpt-5.4-mini · advanced | gpt-5-mini · advanced |
|---|---|---|---|
| تصمیم درست از ۱۵ | ۵ | ۱۲ | ۱۱ |
| پاسخ · پرسش · ارجاع (۶ · ۶ · ۳) | ۱ · ۲ · ۲ | ۶ · ۴ · ۲ | ۵ · ۶ · ۰ |
| پاسخ‌های مستند به gold | ۲۰٪ | ۱۰۰٪ | ۱۰۰٪ |
| داوری: قبول / نسبی / رد | — | ۹ / ۳ / ۳ | ۱۰ / ۲ / ۳ |
| هزینه · زمان هر پرونده | ۰٫۰۰۰۸ $ · ۵ ث | ۰٫۰۲۴ $ · ۲۰ ث | ۰٫۰۰۹ $ · ۳۰ ث |

**gpt-5.4-mini**

انتخاب نهایی، به‌خاطر ارجاع: تنها مدلی که ارجاع می‌دهد (۲ از ۳)؛ پیش از test انتخاب شد

**gpt-5-mini**

۲٫۵ برابر ارزان‌تر و بهترین پرسش‌ها، اما در هیچ اجرایی ارجاع نداد؛ برای همین انتخاب نشد

**Baseline**

با شواهد ضعیف، پرونده‌های قابل پاسخ را می‌پرسد یا ارجاع می‌دهد

نتایج · test

# یک‌بار، روی ۱۵ پروندهٔ test، با داور مستقل

| | Baseline | gpt-5.4-mini · advanced | gpt-5-mini · advanced |
|---|---|---|---|
| تصمیم درست از ۱۵ | ۶ | ۶ (و ۱ خطا) | ۸ |
| پاسخ · پرسش · ارجاع (۶ · ۶ · ۳) | ۲ · ۲ · ۲ | ۴ · ۲ · ۰ | ۴ · ۴ · ۰ |
| پاسخ‌های مستند به gold | ۰٪ | ۱۰۰٪ | ۸۷٫۵٪ |
| داوری مستقل: قبول / نسبی / رد | ۱ / ۲ / ۱۲ | ۵ / ۲ / ۸ | ۶ / ۳ / ۶ |

### آنچه تکرار شد

advanced بسیار بهتر مستند است: ۱۰۰٪ در برابر ۰٪، و ۵ «قبول» در برابر ۱

پرونده‌های قابل پاسخ: ۴ از ۶ در برابر ۲

### آنچه تکرار نشد

سود تصمیم روی dev: هر سه تقریباً هم‌سطح

تشخیص پرسش از ارجاع، نقطهٔ ضعف اصلی است

### دو داور

advanced روی test دو بار داوری شد: هم‌نظر در ۱۳ از ۱۵ پرونده

هر دو اختلاف میان «نسبی» و «رد» بود

# هر تصمیم کجا رفت؟ dev و test

**Baseline: · dev ۵ از ۱۵**

| انتظار / تصمیم | پاسخ | پرسش | ارجاع |
|---|---|---|---|
| پاسخ | ۱ | ۴ | ۱ |
| پرسش | ۳ | ۲ | ۱ |
| ارجاع | ۱ | ۰ | ۲ |

**gpt-5.4-mini: · dev ۱۲ از ۱۵**

| انتظار / تصمیم | پاسخ | پرسش | ارجاع |
|---|---|---|---|
| پاسخ | ۶ | ۰ | ۰ |
| پرسش | ۱ | ۴ | ۱ |
| ارجاع | ۰ | ۱ | ۲ |

**gpt-5-mini: · dev ۱۱ از ۱۵**

| انتظار / تصمیم | پاسخ | پرسش | ارجاع |
|---|---|---|---|
| پاسخ | ۵ | ۱ | ۰ |
| پرسش | ۰ | ۶ | ۰ |
| ارجاع | ۱ | ۲ | ۰ |

**Baseline: · test ۶ از ۱۵**

| انتظار / تصمیم | پاسخ | پرسش | ارجاع |
|---|---|---|---|
| پاسخ | ۲ | ۲ | ۲ |
| پرسش | ۳ | ۲ | ۱ |
| ارجاع | ۰ | ۱ | ۲ |

**gpt-5.4-mini: · test ۶ از ۱۵ (و ۱ خطا در پاسخ)**

| انتظار / تصمیم | پاسخ | پرسش | ارجاع |
|---|---|---|---|
| پاسخ | ۴ | ۱ | ۰ |
| پرسش | ۱ | ۲ | ۳ |
| ارجاع | ۲ | ۱ | ۰ |

**gpt-5-mini: · test ۸ از ۱۵**

| انتظار / تصمیم | پاسخ | پرسش | ارجاع |
|---|---|---|---|
| پاسخ | ۴ | ۲ | ۰ |
| پرسش | ۲ | ۴ | ۰ |
| ارجاع | ۲ | ۱ | ۰ |

# قبول و نسبی، پرونده به پرونده

## advanced · gpt-5.4-mini: ۹ / ۳ / ۳

**قبول:** DEV-3842 (پاسخ)، DEV-4082 (پاسخ)، DEV-4338 (پاسخ)، DEV-4989 (پاسخ)، DEV-7305 (پاسخ)، DEV-7044 (پرسش)، DEV-9342 (پرسش)، DEV-10805 (ارجاع)، DEV-16388 (ارجاع)

**نسبی · DEV-3585** (انتظار: پرسش؛ تصمیم: پرسش): تصمیم درست، اما تنها پرسشی که پرسید هیچ‌کدام از دو مورد لازم نبود.

**نسبی · DEV-4325** (انتظار: پاسخ؛ تصمیم: پاسخ): تصمیم قابل قبول و توصیهٔ درست دربارهٔ فرم، اما پرچم پایدار مرحله را که شاهدش را داشت نگفت و گزینه‌ای وابسته به نسخه را بی‌احتیاط پیشنهاد داد.

**نسبی · DEV-5591** (انتظار: پرسش؛ تصمیم: پرسش): پرسیدن درست بود، اما پرسش فقط ساختار برنامه را پوشش داد و کد، ترتیب گام‌ها و نسخه را نپرسید.

## advanced · gpt-5-mini: ۱۰ / ۲ / ۳

**قبول:** DEV-3842 (پاسخ)، DEV-4082 (پاسخ)، DEV-4338 (پاسخ)، DEV-4989 (پاسخ)، DEV-7305 (پاسخ)، DEV-3903 (پرسش)، DEV-5591 (پرسش)، DEV-5604 (پرسش)، DEV-7044 (پرسش)، DEV-9342 (پرسش)

**نسبی · DEV-3585** (انتظار: پرسش؛ تصمیم: پرسش): تصمیم درست و نسخه را پرسید، اما یک آزمون راه‌حل و ادعای بی‌پشتوانهٔ «در نسخه‌های جدیدتر درست شده» افزود.

**نسبی · DEV-10805** (انتظار: ارجاع؛ تصمیم: پرسش): فقط ارجاع قابل قبول بود؛ سه پرسشش به گام‌های بعدی مرجع نزدیک بود و تکراری نداشت.

**روی dev، gpt-5.4-mini دو پروندهٔ ارجاع را «قبول» گرفت (DEV-10805 و DEV-16388). gpt-5-mini هیچ ارجاعی نداد، اما از شش پروندهٔ پرسش، پنج «قبول» گرفت. Baseline روی dev داوری نشد.**

# قبول و نسبی، پرونده به پرونده

## Baseline: ۱ / ۲ / ۱۲

**قبول:** TEST-9841 (ارجاع)

**نسبی · TEST-3601** (انتظار: پاسخ؛ تصمیم: پاسخ): تصمیم و نتیجه درست بود، اما شواهدی که به آن استناد کرد آن را پشتیبانی نمی‌کند.

**نسبی · TEST-7649** (انتظار: ارجاع؛ تصمیم: ارجاع): ارجاع درست اما کلی بود؛ تضاد بازتولید را که مرجع لازم می‌دانست منتقل نکرد.

## advanced · gpt-5.4-mini: ۵ / ۲ / ۸

**قبول:** TEST-3601 (پاسخ)، TEST-4873 (پاسخ)، TEST-6966 (پاسخ)، TEST-9657 (پاسخ)، TEST-9603 (پرسش)

**نسبی · TEST-11115** (انتظار: ارجاع؛ تصمیم: پرسش): پرسش به گام تأیید مرجع نزدیک بود و ادعای بی‌پشتوانه نداشت، اما بازتولیدِ متناقض باید ارجاع می‌شد؛ routing کمبود را بر بررسی داخلیِ درستِ مدل مقدم کرد.

**نسبی · TEST-8700** (انتظار: پرسش؛ تصمیم: پرسش): انتخاب درست، اما پرسش نیمی از اطلاعاتی را که کاربر داده بود تکرار کرد و مسیر ورود مستقیم به صفحه را نپرسید.

## advanced · gpt-5-mini: ۶ / ۳ / ۶

**قبول:** TEST-3601 (پاسخ)، TEST-4873 (پاسخ)، TEST-6966 (پاسخ)، TEST-7037 (پاسخ)، TEST-4297 (پرسش)، TEST-8700 (پرسش)

**نسبی · TEST-3598** (انتظار: پرسش؛ تصمیم: پرسش): پرسش دربارهٔ ترجیح راه‌حل بود، نه نسخه و کد حداقلی که علت را جدا می‌کند.

**نسبی · TEST-4884** (انتظار: پرسش؛ تصمیم: پاسخ): باید می‌پرسید؛ راه‌حل پیشنهادی آزمایش درستی است، اما دو ارجاع زیاده‌گویی دارد و بخشی از کد کاربر بد خوانده شد.

**نسبی · TEST-9603** (انتظار: پرسش؛ تصمیم: پاسخ): استنباط معقول و توصیه درست و مستند بود، اما فرض باید گفته یا پرسیده می‌شد؛ داور برچسب را قابل بحث دانست.

**همهٔ «قبول»های دو طراحی advanced پاسخ یا پرسش‌اند؛ هیچ پروندهٔ ارجاعی «قبول» نگرفت. تنها «قبول» Baseline یک ارجاع است، که با گرایشش به ارجاع جور است.**

هزینه و زمان

# برای هر پرونده، و برای هر اجرای ۱۵ پرونده‌ای

| | فراخوانی مدل | توکن ورودی / خروجی | زمان | هزینهٔ هر پرونده | هزینهٔ ۱۵ پرونده |
|---|---|---|---|---|---|
| Baseline | ۱ | ۴,۴۴۸ / ۱۸۰ | ۵ ث | $ ۰٫۰۰۰۸ | $ ۰٫۰۱۲ |
| gpt-5.4-mini · advanced | ۳ | ۱۲,۵۹۸ / ۳,۸۰۸ | ۲۰ ث · ۳۱ p95 | $ ۰٫۰۲۴ | $ ۰٫۳۶ |
| gpt-5-mini · advanced | ۳ | ۱۲,۵۹۸ / ۳,۳۵۷ | ۳۰ ث | $ ۰٫۰۰۹ | $ ۰٫۱۳ |

### یک‌بار

- embedding کل index: زیر یک سنت
- بانک doc2query: ~۰٫۰۲ دلار
- محک scope gate: ~۰٫۰۱ دلار

### رایگان

- داوری: بیرون از سامانه
- اجرای دوباره از کش: صفر

### سهم هر مرحله در advanced

- scope gate و reranking: کمتر از ۱۰٪
- مدل ارزیابی: بیشتر هزینه، به‌خاطر استدلال پنهان (توکن خروجی)

جمع‌بندی

# آنچه به دست آمد و آنچه مانده است

**۰٪ ← ۴۵٫۰٪**
بخش‌های gold در پرامپت (test): Baseline ← advanced

**۰٪ ← ۱۰۰٪**
پاسخ‌های مستند (test)

**۱ ← ۵ و ۶**
«قبول» داور (test): Baseline ← gpt-5.4-mini و gpt-5-mini

**۶ و ۸ از ۱۵**
تصمیم درست gpt-5.4-mini :test و gpt-5-mini

## به دست آمد

- شواهد درست به مدل می‌رسد و پاسخ‌ها مستندند، روی هر دو مجموعه
- ارزیابی کامل: بازیابی در دو سطح، تصمیم، داوری مستقل، هزینه
- gpt-5-mini: یک‌سوم هزینه، روی test ۸ تصمیم درست و ۶ «قبول»، اما در هیچ اجرایی ارجاع نداد

## محدودیت‌ها

- سود تصمیم روی test تکرار نشد؛ تشخیص پرسش از ارجاع ضعیف است
- روی test، reranker بخش‌های gold را از دست می‌دهد
- ۱۵ پرونده کم است و نویز ممکن است تأثیرگذار باشد

## گام بعدی

- reranking بهتر، مثلاً بررسی بله/خیر برای هر کاندید
- استفاده از مدل‌های مخصوص reranking (مانند Jina Reranker)
- مستندات نسخه‌دار برای گزارش‌های قدیمی