بوت‌کمپ Agentic AI کوئرا · پروژهٔ نهایی

دستیار پشتیبانی فنی Streamlit

از گزارش خطا تا پیگیری پرونده: طراحی، ارزیابی و نتایج

	بخش‌های gold در پرامپت	تصمیم درست از ۱۵	«قبول» داور مستقل از ۱۵	پاسخ‌های مستند به gold
dev	۵٫۷٪ ← ۷۳٫۲٪	۵ / ۱۲ / ۱۱	— / ۹ / ۱۰	۲۰٪ ← ۱۰۰٪
test	۰٪ ← ۴۵٫۰٪	۶ / ۶ / ۸	۱ / ۵ / ۶	۰٪ ← ۱۰۰٪

ترتیب سه عدد: Baseline · gpt-5.4-mini · gpt-5-mini؛ پیکان: Baseline ← advanced. Baseline روی dev داوری نشد.

پروژه	supportdesk — دستیار پشتیبانی فنی برای کاربران Streamlit
دامنهٔ گزارش	بازیابی شواهد، تصمیم و پاسخ، پیگیری پرونده، ارزیابی
مجموعهٔ ارزیابی	۱۵ پروندهٔ توسعه، ۸۱ بخش gold؛ ۱۵ پروندهٔ آزمون، ۶۵ بخش gold (یک‌بار اجرا شد)
تاریخ	۲۵ مهر ۱۴۰۵

فهرست مطالب

۱. خلاصهٔ اجرایی ۴

۲. داده و روش ارزیابی ۵

۲-۱. جمع‌آوری داده ۵

۲-۲. پاک‌سازی و پیکرهٔ نهایی ۵

۲-۳. پرونده‌های ارزیابی و کنترل نشت ۶

۲-۴. معیارها ۶

۲-۵. برچسب‌گذاری شواهد gold و اعتبارسنجی ۷

۳. ساختار کد و زیرساخت ۸

۳-۱. دو گراف LangGraph ۹

۴. Baseline ۱۰

۵. طراحی نهایی ۱۱

۵-۱. بازیابی شواهد ۱۲

۵-۲. ارزیابی ساختاریافته و routing ۱۲

۵-۳. دو اصلاح در مرحلهٔ پاسخ ۱۲

۵-۴. scope gate و chunking ۱۳

۵-۵. مرحلهٔ پاسخ از نزدیک ۱۳

۶. نتایج ۱۶

۶-۱. بازیابی ۱۶

۶-۲. تصمیم و پاسخ ۱۷

۶-۳. مجموعهٔ test ۱۷

۶-۴. ماتریس‌های درهم‌ریختگی ۱۸

۶-۵. داوری پرونده‌به‌پرونده ۱۹

۷. چرا پرسش‌های doc2query ماند ۲۱

۸. روش‌های آزموده‌شده در هر مرحله ۲۲

۸-۱. آماده‌سازی پرسش ۲۲

۸-۲. جست‌وجو ۲۲

۸-۳. chunking ۲۳

۸-۴. reranking ۲۳

۸-۵. بودجه و حلقه ۲۴

۸-۶. مرحلهٔ پاسخ ۲۵
۸-۷. آزمایش‌های مرحلهٔ پاسخ با شواهد منتخب ۲۵
۹. تحلیل خطا با داور LLM ۲۷
۹-۱. روش ۲۷
۹-۲. دور نخست: خطاهای طراحی پیشین ۲۷
۹-۳. دور دوم: سه طراحی ۲۸
۹-۴. دور سوم: مجموعهٔ test ۲۹
۱۰. اصلاح‌ها: از یافته‌های داور تا طراحی نهایی ۳۰
۱۰-۱. چهار الگو و آنچه انجام شد ۳۰
۱۰-۲. روند آزمودن: آزمون اولیهٔ ارزان، تأیید با مدل اصلی ۳۰
۱۰-۳. اثر اصلاح‌ها، و آنچه پس از داوری آزموده شد ۳۱
۱۱. انتخاب مدل پاسخ ۳۳
۱۲. پیگیری پرونده (مسئلهٔ ۲) ۳۴
۱۳. هزینه و زمان ۳۶
۱۴. رابط وب ۳۸
۱۵. محدودیت‌ها و گام‌های بعدی ۳۹
۱۵-۱. محدودیت‌ها ۳۹
۱۵-۲. گام‌های بعدی ۳۹

۱. خلاصهٔ اجرایی

طراحی نهایی شواهد درست را به مدل می‌رساند و پاسخ‌هایش مستندند، روی هر دو مجموعه: بخش‌های gold در پرامپت روی dev از ۵٫۷٪ به ۷۳٫۲٪ رسید، و روی test پاسخ‌های مستند به gold از ۰٪ (Baseline) به ۱۰۰٪. سود تصمیم روی dev (۱۲ در برابر ۵ از ۱۵) روی test تکرار نشد (۶ در برابر ۶).

۴۵٫۰٪ / ۷۳٫۲٪
بخش‌های gold در پرامپت، test / dev
(Baseline: ۰٪ / ۵٫۷٪)

۱۲ / ۶ از ۱۵
تصمیم درست، test / dev
(Baseline: ۶ / ۵)

۸ / ۲ / ۵
داوری مستقل روی test: قبول / نسبی / رد
(Baseline: ۱۲ / ۲ / ۱)

بازیابی: scope gate گزارش‌های نامربوط را پیش از هر هزینه کنار می‌گذارد. متن گزارش پاک می‌شود، جای ثابتی برای مستندات کنار گذاشته می‌شود، برای هر بخش مستندات از پیش پرسش‌هایی به زبان کاربر ساخته شده است (doc2query)، یک reranker کاندیدها را مرتب می‌کند و هر chunk تا کل بخش مستندات گسترش می‌یابد.

پاسخ: مدل (gpt-5.4-mini) یک ارزیابی ساختاریافته می‌نویسد و یک قاعدهٔ پایتون پاسخ، پرسش یا ارجاع را انتخاب می‌کند. دو اصلاح پس از داوری اضافه شد: یادداشت نسخه روی هر منبع، و پرسش کامل.

test: طراحی پیش از باز کردن test انتخاب شد. روی test، تعداد تصمیم‌های درست برابر Baseline است و نسخهٔ ارزان‌تر با gpt-5-mini هشت تصمیم درست دارد؛ اما کیفیت پاسخ‌ها تفاوت بزرگی دارد (۵ «قبول» در برابر ۱). دو داور مستقل روی ۱۳ پرونده از ۱۵ هم‌نظر بودند. نقطهٔ ضعف اصلی، تشخیص پرسش از ارجاع است، و در بازیابی، reranker.

۲. داده و روش ارزیابی

دامنهٔ پروژه به وضعیت نشست Streamlit و تعامل آن با ویجت، کال‌بک، فرم و برنامه‌های چندصفحه‌ای محدود شد. از چهار منبع عمومی یک پیکرهٔ ثابت ۵۴۰ رکوردی ساخته شد و ۳۰ پروندهٔ ارزیابی (۱۵ توسعه و ۱۵ آزمون) کاملاً بیرون از جست‌وجو نگه داشته شد.

۲-۱. جمع‌آوری داده

Streamlit موضوعات بسیار گسترده‌ای دارد (نصب، ظاهر، پایگاه داده، کش، استقرار و خود وضعیت نشست). اگر همهٔ آن‌ها وارد مجموعه می‌شد، بازیابی با متن نامربوط اشباع می‌شد؛ برای همین تنها ایشوهایی پذیرفته شد که مسئلهٔ **اصلی**شان وضعیت نشست است، نه ایشویی که فقط یک‌بار به `session_state` اشاره کرده باشد.

- **چهار منبع:** ایشوهای مخزن Streamlit (گزارش مشکل)، کامنت‌های همان ایشوها، مستندات رسمی، و یادداشت‌های انتشار (چه چیزی در هر نسخه تغییر کرد). یادداشت انتشار به دستیار کمک می‌کند قاعدهٔ مستندات امروز را به نسخهٔ قدیمی کاربر تعمیم ندهد.
- **دریافت یک‌باره و محلی:** ایشوها و کامنت‌ها با GitHub API دریافت و محلی ذخیره شدند؛ مستندات از یک commit مشخص (pinned) آمد، نه از صفحهٔ زندهٔ سایت که هر روز ممکن است عوض شود. هنگام ارزیابی هیچ چیز دوباره از وب خوانده نمی‌شود.
- **ادغام دو گردآوری:** یک گردآوری متمرکز (۲۲۰ ایشو، ۹۵۴ کامنت) با گردآوری دوم (۵۰۰ ایشو، ۲٬۳۸۴ کامنت) ادغام شد و پس از حذف تکراری‌ها ۶۹۰ ایشو و ۳٬۱۸۱ کامنت یکتا ماند.



شکل ۱ — فیلتر ایشوها.

۲-۲. پاک‌سازی و پیکرهٔ نهایی

پاک‌سازی در چهار لایهٔ جدا انجام شد و فقط روی نسخهٔ محلی:

نسخه	کار	رکورد
۳	چه چیزی اصلاً وارد شود: پیام اجتماعی یا خالی، پیشنهاد تعمیر بدون تأیید رسمی، تصویر و ویدیو، نام API نادرست و بخش نامربوط مستندات کنار رفتند؛ از ۶۲۳ کامنت واجد شرایط ۲۱۴ انتخاب شد	۴۷۲

نسخه	کار	رکورد
۴	شلوغی قالب GitHub (عنوان‌های خالی، تیک‌های پرنشده، تشکر و @نام) بیرون از بلوک‌های کد حذف شد؛ حجم متن حدود ۲٫۶٪ کم شد و ۳۳ مقدار نادرست محیط در ۱۲ ایشو خالی شد	۴۷۲
۵	لینک‌های فنی داخل متن دنبال شد و محتوای صفحه‌های مستندات و مراجع با نشانی ثابت به‌عنوان رکورد تازه افزوده شد؛ مستندات از ۲۱ به ۵۴ صفحه رسید	۵۴۰
۶	متن ۵۴۰ رکورد ثابت شد (حتی یک فاصله تغییر نمی‌کند، چون بازه‌های شواهد با شمارهٔ نویسه ذخیره می‌شوند) و کار روی پرونده‌های ارزیابی متمرکز شد	۵۴۰

۲۱۴ + ۱۲۶
ایشو + کامنت

۱۱۱ + ۵۴
صفحهٔ مستندات + بند انتشار

۳۵
مرجع لینک‌شده (بحث یا کد با نشانی ثابت)

پیکره پیش از indexing به chunkهای حداکثر ۵۱۲ توکنی با همپوشانی ۱۲۸ توکن بریده می‌شود (حدود ۶۳۶ chunk) و هر chunk با text-embedding-3-small به embedding تبدیل می‌شود. چهار روش chunking با جست‌وجوی کلیدواژه‌ای مقایسه شد و روش «آگاه از عنوان و مراقب بلوک کد» بهترین بود (امتیاز ۰٫۱۶۱ در برابر ۰٫۰۶۸ پنجرهٔ ثابت)؛ اما در پایپ‌لاین کامل ما، با جست‌وجوی برداری، reranking و تکمیل بخش، پنجرهٔ ثابت بهتر ماند (فصل ۸).

۲-۳. پرونده‌های ارزیابی و کنترل نشت

- **۳۰ پرونده در دو بخش جدا:** ۱۵ توسعه (۶ قابل پاسخ، ۶ نیازمند پرسش، ۳ نیازمند ارجاع) و ۱۵ آزمون. روی مجموعهٔ توسعه روش تنظیم می‌شود و مجموعهٔ آزمون فقط یک‌بار، روی طراحی نهایی، اجرا می‌شود.
- **سه فایل جدا:** رکوردهای پیکره، ورودی دستیار (گزارش کاربر و محیط، بدون پاسخ)، و فایل ارزیاب (دسته، گام قابل قبول، نتیجه‌گیری نادرست، بازه‌های شواهد مرجع، اطلاعات لازم و اطلاعات معلوم). دستیار هرگز فایل ارزیاب را نمی‌بیند.
- **کنترل نشت:** ایشوی هر پرونده، کامنت‌هایش، ایشوهای بسیار نزدیک به آن (مثلاً دو ایشوی تقریباً یکسان در دو سوی توسعه و آزمون) و شش بند انتشار که فقط به همین شماره‌ها اشاره می‌کردند، پیش از chunking کنار گذاشته و پیش از ساخت index ممیزی می‌شوند. فیلتر تاریخ فقط در نسخهٔ «تاریخی» ارزیابی فعال است؛ پرونده‌های توسعه تاریخی نیستند.
- **زبان ارزیابی:** پاسخ‌ها به انگلیسی، زبان داده‌ها، تولید و سنجیده می‌شوند؛ این گزارش به فارسی است.

۲-۴. معیارها

معیار	تعریف
بخش‌های gold رسیده به مدل (معیار اصلی بازیابی)	سهم بخش‌های gold که دست‌کم ۸۰٪ متنشان در شواهدِ واقعاً فرستاده‌شده به مدل هست؛ معادل Passage Recall@k روی همان شواهد.
Recall@k، Hit@k، MRR	همان سنجش در k chunk نخست؛ سهم پرونده‌های دارای دست‌کم یک بخش gold؛ میانگین معکوس رتبهٔ نخستین بخش gold (کیفیت ترتیب).

معیار	تعریف
تصمیم درست (معیار اصلی سامانه)	تصمیم ذخیره‌شده (پاسخ، پرسش یا ارجاع) یکی از تصمیم‌های قابل دفاع پرونده است؛ به تفکیک سه دسته و با ماتریس تصمیم گزارش می‌شود تا خودداری از پاسخ در همهٔ پرونده‌ها موفقیت شمرده نشود.
پاسخ مستند به شواهد gold	سهم پاسخ‌هایی که دست‌کم به یک منبع gold استناد می‌کنند؛ همراه با ارجاع‌های نامعتبر و پاسخ‌های بی‌ارجاع.
کیفیت پاسخ (داوری)	پشتیبانی هر ادعا با شواهد، درستی و کامل‌بودن پرسش، قابل دفاع بودن تصمیم؛ با داور LLM مستقل (فصل ۹).
هزینه و زمان	فراخوانی‌ها، توکن ورودی و خروجی، هزینه، زمان پاسخ و شمار گام‌ها برای هر پرونده (فصل ۱۳).

معیار اصلی بازیابی در سطح بخش است نه صفحه، چون مدل فقط از متنی استفاده می‌کند که واقعاً دریافت کرده است. برای تحلیل شکست، هر بخش gold در یکی از چهار وضعیت قرار می‌گیرد: **رسیده به مدل**، **حذف‌شده در reranking**، **صفحهٔ درست با chunk دیگر**، یا **صفحه‌ای که اصلاً جزو کاندیدها نبود**.

۲-۵. برچسب‌گذاری شواهد gold و اعتبارسنجی

صلاحیت منابع در metadata: هر رکورد، جدا از متن، شناسه، نوع، checksum متن و فیلدهای منشأ دارد: نسخه یا commit منبع، تاریخ، نقش شاهد (مثلاً مستندات رسمی یا گزارش تاریخی)، قید استفاده و وضعیت بازبینی. هر ۱۲۶ ایشو «گزارش‌شده» علامت خورده‌اند، نه «بازتولیدشده»؛ هر ۲۱۴ کامنت برای بازیابی بازبینی شده‌اند، اما درستی‌شان در اجرا تأیید نشده است. همین فیلدهای نسخه و نقش، ورودی یادداشت نسخه در مرحلهٔ پاسخ‌اند (۵-۳). درس اصلی: منبع معتبر می‌تواند برای یک ادعای خاص شاهد نامناسب باشد؛ قاعدهٔ امروز هویت ویجت، یک راه‌حل پیشنهادی کاربران و یک ناسازگاری قدیمی میان frontend و backend، سه نوع شاهد متفاوت‌اند.

ساختار پرونده‌های dev: افزون بر سه دستهٔ تصمیم (۲-۳)، از نظر موضوع سه پرونده برای هر یک از مقداردهی اولیه، چرخهٔ عمر ویجت، callbackها، فرم‌ها و برنامهٔ چندصفحه‌ای. برچسب اولیهٔ شواهد فقط ۱۸ بازهٔ یکتا از شش صفحهٔ مستندات بود؛ بازبینی نشان داد یک دستهٔ اصلی واحد گاهی چند اقدام قابل دفاع را نمی‌پوشاند، پس بی‌آنکه ورودی‌ها یا دسته‌ها تغییر کنند، قیدهای شرطی به فایل ارزیاب افزوده شد (مثلاً نسخه‌ای را که کاربر داده دوباره نپرس).

شواهد gold برچسب‌خورده	dev	test
بخش‌های gold (بازه‌های دقیق)	۸۱	۶۵
رکوردهای منبع یکتا	۲۲	۲۰
بخش در هر پرونده	متغیر	۳ تا ۶
نوع منابع	عمدتاً مستندات	مستندات، ۴ کامنت، ۳ بند انتشار

واحد برچسب: هر بخش gold یک شناسه، متن عیناً از منبع، شمارهٔ نویسهٔ شروع و پایان (شروع شامل، پایان غیرشامل، بر پایهٔ code point)، شمارهٔ خط و checksum دارد. بلوک کد هرگز نیمه بریده نمی‌شود و چند بازهٔ جدا از یک منبع جدا می‌مانند. اعتبارسنج این‌ها را دوباره محاسبه می‌کند: متن هر بخش باید دقیقاً با بازهٔ منبع برابر باشد، بازه‌ها مرتب، در

محدوده و بدون هم‌پوشانی باشند، و منابع و خانواده‌های ممنوع (ایشوی خود پرونده‌ها) استفاده نشده باشند. این بخش‌ها مرجع معیارهای سطح بخش ما هستند (قاعدهٔ ۸۰٪، ۲-۴) و هرگز ورودی سامانه نیستند.

ممیزی نشت و افشا: ممیزی dev روی index ۶۳۶ chunkی هیچ نشت قطعی و هیچ هشداری نیافت، و بررسی واژگانی ۶۵ بخش test در برابر ۳۰ گزارش ارزیابی هم بدون مورد بود. این بررسی‌ها نشت مکانیکی را کم می‌کنند، اما نبود هر نشت معنایی را ثابت نمی‌کنند. برچسب‌گذاری dev پس از دیدن گزارش‌ها و برچسب‌ها انجام شد، و برچسب‌گذاری test با کمک شواهد gold بود؛ پس هیچ‌کدام کاملاً کور نیست. بخش‌های dev در ۱۵ اکتبر ۲۰۲۶ دستی انتخاب شدند، و فایل‌های ارزیاب با کمک دستیار هوش مصنوعی نوشته شده‌اند.

۳. ساختار کد و زیرساخت

> سامانه با Python نوشته شده و هر پایپ‌لاین یک گراف LangGraph از مرحله‌های قابل تعویض است؛ هر آزمایش تنها یک مرحله یا یک تنظیم را تغییر می‌دهد تا اثر همان تغییر جدا دیده شود.

بخش	وظیفه	دلیل انتخاب
گراف indexing	بارگذاری، غربال، chunking، ممیزی نشت، Embedding و ذخیره	index قابل بازتولید؛ مدل و chunking در manifest ثبت و هنگام بارگذاری بررسی می‌شوند
گراف پشتیبانی	پرسش، بازیابی، reranking، بستهٔ شواهد، ارزیابی، routing، خلاصه	مرحله‌ها مستقل از هم تعویض می‌شوند؛ ده‌ها آزمایش بدون تغییر کد مشترک
گراف پرونده	پیگیری چندنوبتی پیرامون گراف پشتیبانی، رهگیر محلی، توقف برای تأیید انسانی	نقطه‌های بازیابی SQLite و توقف گراف برای تأیید در خود LangGraph
مخزن برداری	Qdrant محلی	محلی و بدون سرویس بیرونی، پس قابل بازتولید؛ فیلتر روی نوع منبع و تاریخ؛ ذخیرهٔ پایدار روی دیسک
تنظیمات	تنظیمات تایپ‌دار و اعتبارسنجی‌شده، یک index برای هر پایپ‌لاین	هر اجرا همهٔ تنظیمات خود را ثبت می‌کند و گزارش مقایسه تفاوت‌ها را خودکار نشان می‌دهد

- **درگاه مشترک مدل:** همهٔ فراخوانی‌ها از یک درگاه مشترک (متیس) می‌گذرند: کش SQLite (تکرار یک درخواست رایگان است)، دفتر هزینهٔ مشترک میان همهٔ فرایندها، و بررسی بودجه پیش از هر فراخوانی با ذخیرهٔ احتیاطی برای اجرای نهایی. مدل‌ها: gpt-4o-mini برای scope gate، reranking و پاسخ Baseline؛ gpt-5.4-mini برای ارزیابی ساختاریافته؛ text-embedding-3-small برای Embedding.
- **سه حالت اجرا:** offline با مدل جعلی و رایگان برای آزمون‌ها، replay فقط از کش (هرگز هزینه ندارد) و live با فراخوانی واقعی.
- **کیفیت:** Baseline با آزمون اثرانگشت کد و خروجی محافظت می‌شود؛ حدود ۷۰۰ آزمون خودکار و ruff روی Python 3.10 و 3.12 در هر تغییر اجرا می‌شوند.

۳-۱. دو گراف LangGraph

سامانه دو گراف LangGraph دارد. **گراف اول، پاسخ‌گویی:** scope gate، پرسش جست‌وجو، بازیابی، reranking، شواهد و پاسخ (ارزیابی و routing). **گراف دوم، ساخت index:** بارگذاری، غربال، chunking، ممیزی نشت، embedding و ذخیره. اولی برای هر گزارش اجرا می‌شود و دومی یک‌بار، و با manifest به هم وصل‌اند: پایپ‌لاین index ی را که با مدل یا chunking دیگری ساخته شده نمی‌پذیرد.

- **چرا LangGraph:** هر مرحله یک node جداست و هر آزمایش فقط یک مرحله را عوض می‌کند؛ state صریح میان مرحله‌ها خروجی هر مرحله را قابل ثبت می‌کند؛ توقف برای تأیید انسانی (interrupt) و ادامه از همان نقطه (checkpoint) مستقیم پشتیبانی می‌شود؛ و همان گراف در CLI، ارزیابی و رابط وب اجرا می‌شود.
- **مسئلهٔ ۲ جدا نیست:** پیگیری پرونده ادامهٔ همین گراف است. گراف پرونده، پایپ‌لاین را در بر می‌گیرد؛ پاسخ و پرسش مستقیم ثبت می‌شوند، و ارجاع پس از ثبت پیشنهاد در یک tracker محلی، با `interrupt()` متوقف می‌شود. state با یک checkpointer (SQLite) پس از هر node ذخیره می‌شود، پس توقف حتی پس از راه‌اندازی دوباره باقی می‌ماند؛ نگه‌دارنده با تأیید، ویرایش یا رد، گراف را با `Command(resume=...)` از همان نقطه ادامه می‌دهد. تأیید فقط برای همان پیشنهاد معتبر است، پیشنهادی که کاربر پس از آن پیام تازه داده منتشر نمی‌شود، و هر انتشار با شناسهٔ پیشنهاد فقط یک‌بار انجام می‌شود. این مسیر از CLI در دسترس است (`supportdesk case` و `supportdesk review`)؛ رابط وب از آن استفاده نمی‌کند.
- **غربال در ساخت index** یعنی بررسی هر رکورد برای دادهٔ شخصی (ایمیل) و رمز یا کلید API؛ اگر پیدا شود ساخت متوقف می‌شود و متن ویرایش نمی‌شود. حذف پرونده‌های ارزیابی هنگام chunking انجام می‌شود و ممیزی نشت دوباره بررسی‌اش می‌کند.

Baseline .۴

Baseline ساده‌ترین سامانهٔ قابل دفاع و مرجع همهٔ مقایسه‌هاست: روی dev تنها ۵٫۷٪ بخش‌های gold را به مدل می‌رساند و ۵ تصمیم از ۱۵ را درست می‌گیرد؛ روی test هیچ بخش gold و ۶ تصمیم درست. کد و خروجی آن منجمد است و با آزمون محافظت می‌شود.



شکل ۲ — جریان Baseline.

دو علت، بازیابی Baseline را ضعیف می‌کند. نخست، متن گزارش پر از قالب GitHub است (چک‌لیست، اطلاعات اشکال‌زدایی، پرسش‌های ثابت) و بردار جست‌وجو را از مسئلهٔ اصلی دور می‌کند. دوم، گزارش‌های پیشین از نظر واژگان به گزارش تازه نزدیک‌ترند و هر شش جای نتیجه را پر می‌کنند، در حالی که توضیح اصلی معمولاً در مستندات است. با شواهد ضعیف، مدل پاسخ در پرونده‌های قابل پاسخ بیشتر می‌پرسد (۴ از ۶).

۵. طراحی نهایی

طراحی نهایی شواهد را با پنج روش بهتر از Baseline پیدا و انتخاب می‌کند، و تصمیم را از نوشتن پاسخ جدا می‌کند: مدل پرونده را ارزیابی می‌کند و قاعده‌ای در پایتون اقدام را برمی‌گزیند.



شکل ۳ — جریان طراحی نهایی.

۵-۱. بازیابی شواهد

روش	چه می‌کند	چرا
پاک‌سازی گزارش	قالب GitHub (چک‌لیست‌ها، بخش‌های خالی، اطلاعات اشکال‌زدایی تکراری) را حذف می‌کند و عنوان، کد، فراخوانی‌های `st.*` و پیام خطا را نگه می‌دارد.	بردار جست‌وجو به مسئلهٔ اصلی نزدیک می‌شود.
جای ثابت برای مستندات	از ۱۵ کاندید جست‌وجو، ۱۰ جا به مستندات و ۵ جا به گزارش‌ها، نظرها و یادداشت‌ها می‌رسد.	گزارش‌های مشابه دیگر همهٔ جاها را از مستندات نمی‌گیرند.
پرسش‌های doc2query (doc2query)	برای هر یک از ۱۴۶ بخش مستندات، یک مدل زبانی یک‌بار و پیش از اجرا ۵ پرسش به زبان کاربر می‌نویسد که آن بخش پاسخشان است (مثلاً «چرا مقدار ویجت پس از تغییر صفحه پاک می‌شود؟»). هنگام جست‌وجو، گزارش با این پرسش‌ها هم مقایسه می‌شود و ۱۵ بخشِ نزدیک‌تر به کاندیدها افزوده می‌شوند.	کاربر علامت را توصیف می‌کند، نه سازوکار را؛ این پرسش‌ها کمبود واژگانی میان گزارش و مستندات را می‌بندند. هزینهٔ ساخت حدود ۰٫۰۲ دلار است.
reranking با مدل زبانی	یک فراخوانی gpt-4o-mini همهٔ کاندیدها را با دیدن ۴۰۰ نویسهٔ منطبق‌تر هر کدام رتبه می‌دهد؛ ۸ کاندید برتر، دست‌کم ۵ از مستندات، نگه داشته می‌شوند.	شباهت برداری مرتبط را از توضیح‌دهنده جدا نمی‌کند؛ بدون reranking بخش‌های gold از ۷۰٫۱٪ به ۶۴٫۳٪ می‌افتد.
تکمیل بخش	هر chunk مستندات تا کل بخش‌هایی که در آن‌ها افتاده گسترش می‌یابد (حداکثر ۹۰۰ توکن) و chunkهای هم‌پوشان یک صفحه ادغام می‌شوند.	chunkهای ۵۱۲ توکنی بخش‌ها را می‌برند؛ مدل باید بخش را کامل ببیند.

۵-۲. ارزیابی ساختاریافته و routing

مدل پاسخ (gpt-5.4-mini با استدلال متوسط) به‌جای نوشتن مستقیم پاسخ، یک ارزیابی ساختاریافته در طرح‌وارهٔ JSON سخت‌گیرانه می‌نویسد: نیاز اصلی کاربر، واقعیت‌های معلوم هرکدام با شاهد، کمبودهای اطلاعاتی و اینکه آیا هر کمبود برای تصمیم اساسی است، و نیاز به بررسی داخلی. سپس قاعده‌ای در پایتون اقدام را انتخاب می‌کند (ترتیب کامل قواعد در ۵-۵). همین قاعده پاسخ کاربر و خلاصهٔ نگهدارنده (مسئله، محیط، واقعیت‌ها با منبع، پرسش‌های باز و قدم بعدی) را می‌سازد.

جداکردن تصمیم از نوشتن دو مزیت دارد: تصمیم قابل بررسی و آزمون‌پذیر است، و مدل نمی‌تواند با یک پاسخ روان از کمبود اطلاعات بگذرد. پاسخ نامعتبر، ناقص یا ردشده خطای همان پرونده شمرده می‌شود، نه ارجاع، تا خطای سامانه به‌جای تصمیم درست ننشیند.

۵-۳. دو اصلاح در مرحلهٔ پاسخ

پرامپت مدل همان پرامپت بستهٔ پاسخ (controlled_v2) است و تغییر نکرده؛ دو اصلاح پیش و پس از فراخوانی مدل، در کد پایتون، اضافه شده‌اند (جزئیات و نتیجه در فصل ۱۰):

- **یادداشت نسخه (پیش از مدل):** روی هر منبع دو یادداشت محاسبه‌شده در کد قرار می‌گیرد، از روی نوع، نسخه و تاریخ منبع و نسخهٔ گزارش‌شدهٔ کاربر: منبع چه نسخه‌ای را توصیف می‌کند و چگونه باید به کار رود. ورودی مدل تغییر می‌کند، دستورهایش نه.

- **پرسش کامل (پس از routing):** اگر تصمیم پرسیدن است، پاسخ همهٔ پرسش‌هایی را که مدل برای کمبودهای مهم نوشته در یک فهرست شماره‌دار می‌آورد، نه فقط اولی را. خروجی مدل و تصمیم تغییر نمی‌کنند؛ فقط متنی که به کاربر می‌رسد کامل‌تر می‌شود.

> **پیش‌نیاز:** بانک پرسش‌های doc2query (`scripts/build_section_questions.py`) باید ساخته شده باشد و با هر تغییر مستندات دوباره ساخته شود؛ بدون آن، سامانه متوقف می‌شود و همین دستور را برای ساختنش نشان می‌دهد.

۵-۴. scope gate و chunking

scope gate: یک فراخوانی کوچک gpt-4o-mini پیش از بازیابی تصمیم می‌گیرد گزارش دربارهٔ Streamlit هست یا نه؛ گزارش نامربوط به‌جای پاسخ یک پرسش ثابت می‌گیرد (تصمیم «پرسش»): «لطفاً یک پرسش، خطا یا نمونهٔ کد کوچک Streamlit بفرستید»، بدون هزینهٔ بازیابی و مدل پاسخ. پرونده باز می‌ماند؛ وقتی کاربر پیام تازه‌ای می‌فرستد، scope gate دوباره اجرا می‌شود و این بار عنوان، متن و پیام‌های پیگیری خود کاربر (نه پیام‌های دستیار) را با هم می‌خواند. اگر گزارش حالا دربارهٔ Streamlit باشد، پایپ‌لاین کامل اجرا می‌شود. بدون پیام پیگیری، ورودی همان عنوان و متن است، پس نتیجه‌های کش‌شدهٔ ارزیابی معتبر می‌مانند. روی محکی با ۱۲۰ گزارش (۶۰ مرتبط، ۶۰ نامربوط)، همه را درست تشخیص داد، بدون رد اشتباه هیچ گزارش مرتبط (هزینهٔ کل حدود ۰٫۰۱ دلار)؛ gpt-4.1-nano یک پذیرش اشتباه داشت. روی test هر ۱۵ گزارش واقعی را عبور داد.

پوشش بخش‌های gold در chunkها: ۸۱ بخش gold کوتاه‌اند (میانهٔ ۹۲ توکن). با پنجرهٔ ثابت ۵۱۲ توکنی، ۸۰ بخش کامل و هر ۸۱ دست‌کم ۸۰٪ در یک chunk جا می‌شوند، و شش chunk کاملاً درست‌انتخاب‌شده می‌توانند ۹۸٪ بخش‌ها را بیاورند (chunking ساختاری: ۸۹٪؛ ساختاری با سقف توکن: ۹۶٪). پس chunking گلوگاه نیست و فاصلهٔ باقی‌مانده از جست‌وجو و reranking است.

۵-۵. مرحلهٔ پاسخ از نزدیک

ورودی‌ها: گزارش کاربر (مشکل، کد، پیام خطا، گام‌های بازتولید)، محیطی که کاربر اعلام کرده (نسخهٔ Streamlit و Python، سیستم‌عامل، مرورگر)، شواهد بازیابی‌شده همراه نوع منبع، عنوان، نشانی و نسخه، و مکالمهٔ قبلی همراه تعداد پرسش‌های پرسیده‌شده. گزارش مشابهِ کاربر دیگر نشان می‌دهد کسی مشکل مشابهی دیده است، اما ثابت نمی‌کند علت یکی است؛ مدل باید «گزارش یک مشکل» را از «علت یا راه‌حل تأییدشده» جدا کند.

آماده‌سازی در کد: شناسهٔ پرونده، وجود شواهد، متن غیرخالی و یکتایی شناسه‌ها بررسی می‌شود. به هر بخش شناسهٔ کوتاه داده می‌شود: R برای بخش‌های گزارش، H برای مکالمه و S برای شواهد. بلوک‌های کد یکپارچه می‌مانند، ترتیب شواهد حفظ می‌شود، و میان دو تکهٔ جدا از یک منبع گفته می‌شود که متن میانی ممکن است حذف شده باشد. سقف ورودی ۶۰٬۰۰۰ نویسه و سقف تاریخچه ۱۶٬۰۰۰ نویسه است؛ ورودی بزرگ‌تر خطا می‌دهد و چیزی بی‌خبر حذف نمی‌شود.

درخواست و فرم: قواعد تحلیل می‌گویند «علت ممکن» را از «علت ثابت‌شده» جدا نگه دار، و اگر پاسخ به واقعیتی نامعلوم وابسته است که کاربر می‌تواند روشن کند، ابهام و یک پرسش مفید ثبت شود. مدل فرمی با ساختار ثابت پر می‌کند: نیاز اصلی، ضرورت بررسی انسانی، کمبودهای اطلاعاتی (مهم است؟ کاربر می‌تواند بدهد؟ قبلاً داده؟ چه پرسشی؟ دو نتیجهٔ ممکن و اقدام بعدی هر کدام)، پاسخ پیشنهادی، اصلاحات و نیاز به بررسی داخلی. برچسب و پاسخ مرجع هرگز به مدل

داده نمی‌شود. کد خروجی را بررسی می‌کند: همهٔ فیلدها با نوع درست، هر ارجاع به R، H یا S واقعیِ همان پرونده، و برای هر پرسش مهم دو نتیجه و دو اقدام متفاوت. ساختار درست، درستی تحلیل را ثابت نمی‌کند.

ترتیب قواعد کنترلر (پایتون)	اقدام
بررسی انسانی از ابتدا ضروری است، با دلیل و بخش پشتیبان در گزارش	ارجاع
کمبودی مهم که کاربر می‌تواند بدهد و قبلاً نداده، و هنوز جای پرسش هست (سقف ۵ پرسش؛ پس از آن ارجاع)	پرسش
کمبود مهم حل‌نشده‌ای نمانده و پاسخ پیشنهادی هست	پاسخ
پرسش مفیدی نمانده و بررسی داخلی ثبت شده	ارجاع
هیچ مسیر پشتیبانی‌شده‌ای نیست	خطا، نه ارجاع پیش‌فرض

کنترلر مدل را دوباره صدا نمی‌زند و برچسب پرونده را نمی‌بیند، اما چیزی را که مدل در فرم ثبت نکرده کشف نمی‌کند. **مثال واقعی:** ویجتی با محدودهٔ ۱ تا ۵ مقدار ۱۰ را پذیرفته بود و نسخه اعلام نشده بود. مدل نبودن نسخه را کمبودی مهم و قابل‌پاسخ ثبت کرد و پاسخ نهایی ننوشت؛ کنترلر، با اینکه نیاز احتمالی به بررسی تیم محصول هم ثبت شده بود، پرسیدن نسخه را انتخاب کرد.

فیلد فرم ارزیابی	کاربرد
main_need	مسئلهٔ اصلی کاربر، نه یک مسئلهٔ جانبی
reported_observation_refs	تا شش بخش گزارش یا پیام کاربر، که کد عیناً کپی می‌کند
required_human_review	نیاز مشخص به اختیار، استثنای سیاستی یا بررسی تخصصی امنیت و حریم خصوصی؛ اشکال‌زدایی معمول این نیست
information_gaps	تا سه کمبود: مهم است؟ کاربر می‌تواند بدهد؟ قبلاً داده یا آزموده؟ پرسش و دو نتیجهٔ ممکن
answer_candidate	پاسخ مستند، یا خالی اگر پیش‌فرض مهمی حل نشده
internal_investigation	رفتار حل‌نشده و دلیل نیاز به بررسی داخلی
workflow_findings	تا چهار اصلاح کد، هر کدام با ارجاع به گزارش و شواهد

دو جزء کد، دو خطای مشاهده‌شده را برطرف کرد: نقل‌قول‌های گزارش را کد از روی ارجاع کپی می‌کند (در یک آزمایش، مدل یکی از هشت نقل‌قول را تغییر داده بود)، و در پاسخ، همهٔ اصلاح‌های کدِ شناسایی‌شده آورده می‌شوند (پیش‌تر اصلاحی در فرم بود اما به پاسخ نمی‌رسید). این دو، اطلاعاتِ شناسایی‌شده را حفظ می‌کنند، اما کمبودی را که مدل ندیده جبران نمی‌کنند.

پیام و حافظه: پیام را کد از روی فرم می‌سازد. حافظهٔ مکالمه در برنامه است، نه در مدل: در هر نوبت، کل سابقه و تعداد پرسش‌ها دوباره به مدل می‌رسد. حداکثر ۵ پرسش پیگیری داریم؛ حجم ورودی و بودجه پیش از هر ارسال بررسی می‌شود،

و درخواست تکراری از کش و بدون هزینه پاسخ می‌گیرد. در پایپ‌لاین، شواهد از بازیابی واقعی می‌آید و قطع اتصال یک‌بار دوباره تلاش می‌شود.

چرا این طراحی: نسخه‌های اولیه گاهی علت احتمالی را واقعیت فرض می‌کردند و زود پاسخ می‌دادند، یا به‌جای پرسش ارجاع می‌دادند؛ آزمایش‌هایی که به این طراحی رسید در ۸-۷ آمده است. انتخاب: gpt-5.4-mini، یک فراخوانی، تلاش استدلالی متوسط و سقف ۸,۰۰۰ توکن خروجی.

آزمون مرحلهٔ پاسخ روی dev	تصمیم درست	پاسخ / پرسش / ارجاع
آزمون جداگانه، روی بهترین شواهد (منتخب)	۱۱	۳ / ۳ / ۵
پایپ‌لاین، با شواهد بازیابی‌شده و بدون doc2query	۱۱	۱ / ۴ / ۶
طراحی نهایی (doc2query و دو اصلاح)	۱۲	۲ / ۴ / ۶

۶. نتایج

طراحی نهایی روی dev ۷۳٫۲٪ بخش‌های gold را به مدل می‌رساند و ۱۲ تصمیم از ۱۵ را درست می‌گیرد؛ روی test ۴۵٫۰٪ و ۶ تصمیم درست. بازیابی و مرحلهٔ پاسخ جداگانه سنجیده شده‌اند.

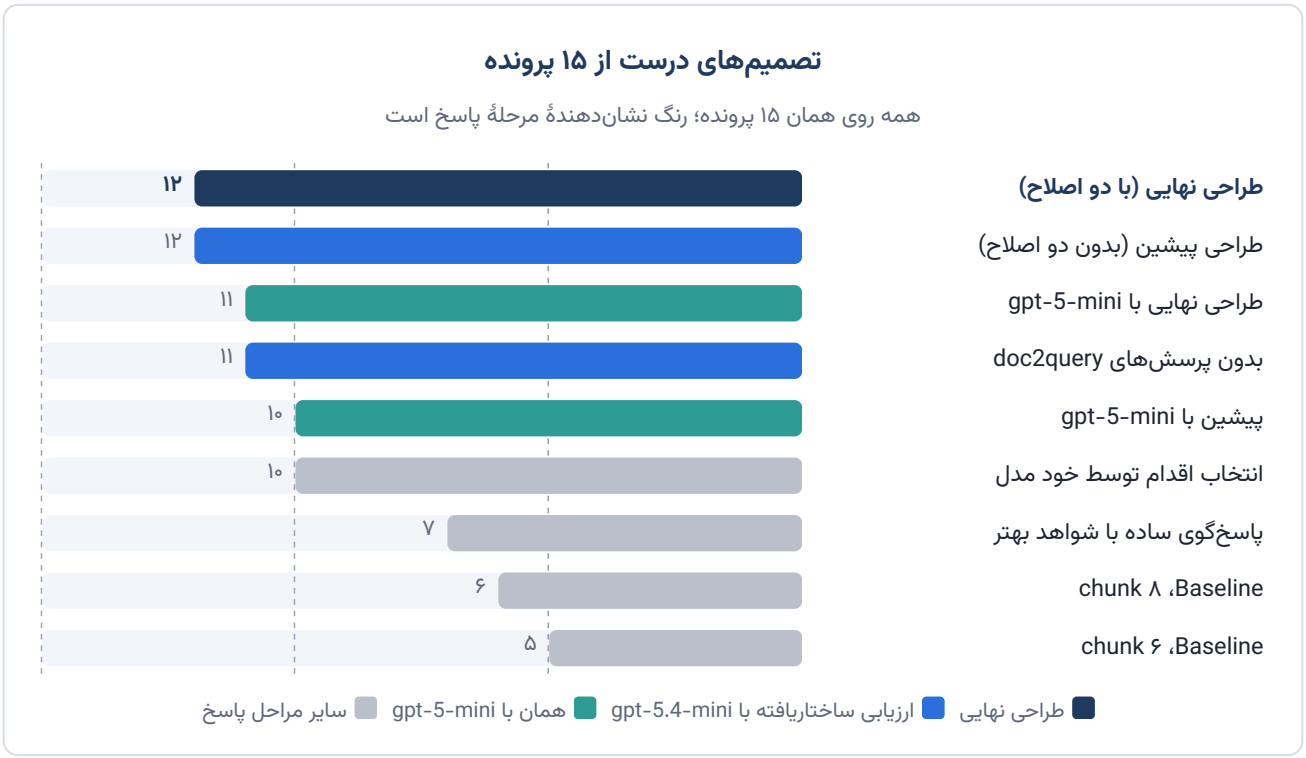
۶-۱. بازیابی



شکل ۴ — اثر هر روش پذیرفته‌شده در بازیابی.

بیشترین اثر از دو گام نخست است: پاک‌سازی گزارش همراه با جای ثابت مستندات (۵٫۷٪ به ۳۹٫۶٪) و reranking با مدل زبانی (به ۵۹٫۱٪). تکمیل بخش در هر طراحی ۵ تا ۸٪ افزود، بودجهٔ ۸ chunk با کمینهٔ ۵ chunk مستندات ۸٪ دیگر، و پرسش‌های doc2query ۳٪. محدودیت باقی‌مانده انتخاب reranker است، نه جست‌وجو؛ روش‌هایی که بهبود ندادند در فصل ۸ آمده‌اند.

۶-۲. تصمیم و پاسخ



شکل ۵ — مرحلهٔ پاسخ عامل اصلی است.

طراحی	قابل پاسخ (۶)	نیازمند پرسش (۶)	نیازمند ارجاع (۳)	هزینهٔ هر پرونده
Baseline، chunk ۸ / ۶	۱ / ۱	۳ / ۲	۲ / ۲	~$ ۰٫۰۰۰۸
پاسخ‌گوی ساده با شواهد بهتر	۵ تا ۶	۰ تا ۱	۰	~$ ۰٫۰۰۲
طراحی پیشین (بدون دو اصلاح)	۶	۵	۱	~$ ۰٫۰۲۱
طراحی نهایی	**۶**	**۴**	**۲**	**~$ ۰٫۰۲۴**
طراحی نهایی با gpt-5-mini	۵	۶	۰	~$ ۰٫۰۰۹

همهٔ طراحی‌های دارای ارزیابی ساختاریافته به شواهد gold استناد می‌کنند (۱۰۰٪). پاسخ‌گوی ساده با gpt-4o-mini در ۱۱ تا ۱۳ پرونده از ۱۵ پاسخ می‌دهد و هیچ پروندهٔ نیازمند ارجاعی را ارجاع نمی‌دهد: شواهد بهتر آن را به پاسخ‌دادن بیشتر متمایل می‌کند، نه به تصمیم بهتر.

۶-۳. مجموعهٔ test

مجموعهٔ test یک‌بار، روی طراحی‌ای که پیش‌تر انتخاب شده بود، اجرا شد. سه طراحی سنجیده شد: Baseline با chunk ۶، طراحی نهایی، و نسخهٔ ارزان‌ترِ آن با gpt-5-mini که از پیش به‌عنوان جایگزین مشخص شده بود.

بازیابی روی test	Baseline	بدون doc2query	طراحی نهایی
بخش‌های gold در پرامپت	۰٪	۵۲٫۶٪	۴۵٫۰٪

بازیابی روی test	Baseline	بدون doc2query	طراحی نهایی
پرونده‌های دارای دست‌کم یک بخش gold	۰٪	۹۳٫۳٪	۹۳٫۳٪
بخش gold در رتبهٔ ۱ / MRR سطح بخش	۰ / ۰٪	۰٫۶۲۴ / ۴۶٫۷٪	۰٫۵۷۶ / ۳۳٫۳٪
صفحه‌های gold در پرامپت / MRR سطح صفحه	۰ / ۰٪	۰٫۶۸۰ / ۵۹٫۴٪	۰٫۷۳۳ / ۶۱٫۷٪

Baseline روی test هیچ شاهد gold نیافت: جست‌وجوی ساده همهٔ جاها را با ایشوها و کامنت‌های مشابه پر کرد، در حالی که شواهد gold عمدتاً مستندات است. در طراحی نهایی، doc2query صفحه‌های درست را بالاتر آورد اما بخش‌های gold کمتری رساند. قیف شواهد علت را نشان می‌دهد: صفحه‌های هرگز پیدانشده از ۱۷ به ۱۰ بخش رسید، اما بخش‌های حذف‌شده در reranking از ۴ به ۱۷؛ همان سازوکاری که روی dev دیده شده بود (۶ به ۱۳)، با نتیجهٔ خالص منفی (۳۴ به ۳۰ بخش در پرامپت).

تصمیم و داوری روی test	Baseline	نهایی (gpt-5.4-mini)	نهایی (gpt-5-mini)
تصمیم درست از ۱۵	۶	۶ (و ۱ خطا)	۸
پاسخ / پرسش / ارجاع (از ۶ / ۶ / ۳)	۲ / ۲ / ۲	۰ / ۲ / ۴	۰ / ۴ / ۴
پاسخ‌های مستند به gold	۰٪	۱۰۰٪	۸۷٫۵٪
داوری مستقل: قبول / نسبی / رد	۱ / ۲ / ۱۲	۵ / ۲ / ۸	۶ / ۳ / ۶

خطای طراحی نهایی (یک پرونده) ارزیابی‌ای بود که هیچ اقدامی را پشتیبانی نمی‌کرد؛ بستهٔ پاسخ عمداً به‌جای حدس، خطا می‌دهد. Baseline با تمایل به ارجاع زیاد، دو پروندهٔ ارجاع را درست گرفت، اما بدون هیچ شاهد gold.

۶-۴. ماتریس‌های درهم‌ریختگی

ردیف‌ها تصمیم مورد انتظار و ستون‌ها تصمیم گرفته‌شده‌اند؛ اعداد پررنگ تصمیم‌های درست‌اند. در test، gpt-5.4-mini یک خطا در پروندهٔ قابل پاسخ هم دارد.

dev

طراحی	انتظار	پاسخ	پرسش	ارجاع
Baseline (۵ از ۱۵)	پاسخ	**۱**	۴	۱
	پرسش	۳	**۲**	۱
	ارجاع	۱	۰	**۲**
gpt-5.4-mini (۱۲ از ۱۵)	پاسخ	**۶**	۰	۰
	پرسش	۱	**۴**	۱
	ارجاع	۰	۱	**۲**

طراحی	انتظار	پاسخ	پرسش	ارجاع
gpt-5-mini (۱۱ از ۱۵)	پاسخ	**۵**	۱	۰
	پرسش	۰	**۶**	۰
	ارجاع	۱	۲	**۰**

test

طراحی	انتظار	پاسخ	پرسش	ارجاع
Baseline (۶ از ۱۵)	پاسخ	**۲**	۲	۲
	پرسش	۳	**۲**	۱
	ارجاع	۰	۱	**۲**
gpt-5.4-mini (۶ از ۱۵)	پاسخ	**۴**	۱	۰
	پرسش	۱	**۲**	۳
	ارجاع	۲	۱	**۰**
gpt-5-mini (۸ از ۱۵)	پاسخ	**۴**	۲	۰
	پرسش	۲	**۴**	۰
	ارجاع	۲	۱	**۰**

روی dev، gpt-5.4-mini همهٔ پرونده‌های قابل پاسخ و دو ارجاع از سه را درست دارد و gpt-5-mini همهٔ پرسش‌ها را، اما ستون ارجاعش خالی است. Baseline زیاد ارجاع می‌دهد و پرسش‌ها را با پاسخ اشتباه می‌گیرد. روی test، ضعف مشترک دو طراحی advanced ستون ارجاع است.

۶-۵. داوری پرونده‌به‌پرونده

dev (Baseline روی dev داوری نشد):

- **gpt-5.4-mini (۹ / ۳ / ۳):** قبول برای DEV-3842، DEV-4082، DEV-4338، DEV-4989 و DEV-7305 (پاسخ)، DEV-7044 و DEV-9342 (پرسش)، و DEV-10805 و DEV-16388 (ارجاع). نسبی: DEV-3585 (پرسید، اما هیچ‌کدام از دو مورد لازم نبود)؛ DEV-4325 (پاسخ درست دربارهٔ فرم، اما واقعیتی را که شاهدش را داشت نگفت و گزینه‌ای وابسته به نسخه را بی‌احتیاط پیشنهاد داد)؛ DEV-5591 (فقط ساختار برنامه را پرسید، نه کد، گام‌ها و نسخه).
- **gpt-5-mini (۱۰ / ۲ / ۳):** قبول برای پنج پروندهٔ پاسخ و پنج از شش پروندهٔ پرسش. نسبی: DEV-3585 (نسخه را پرسید، اما ادعای بی‌پشتوانهٔ «در نسخه‌های جدیدتر درست شده» افزود)؛ DEV-10805 (پرسید، جایی که فقط ارجاع قابل قبول بود).

test (داور بیرونی):

- **Baseline (۱ / ۲ / ۱۲):** قبول برای TEST-9841 (ارجاع). نسبی: TEST-3601 (تصمیم و نتیجه درست، اما شواهد استنادشده آن را پشتیبانی نمی‌کند)؛ TEST-7649 (ارجاع درست اما کلی، بدون تضاد بازتولید).
- **gpt-5.4-mini (۵ / ۲ / ۸):** قبول برای TEST-3601، TEST-4873، TEST-6966 و TEST-9657 (پاسخ) و TEST-9603 (پرسش). نسبی: TEST-11115 (پرسید، جایی که بازتولیدِ متناقض باید ارجاع می‌شد؛ routing کمبود را بر بررسی داخلیِ درستِ مدل مقدم کرد)؛ TEST-8700 (پرسش نیمی از اطلاعاتِ داده‌شده را تکرار کرد و مسیر ورود مستقیم به صفحه را نپرسید).
- **gpt-5-mini (۶ / ۳ / ۶):** قبول برای TEST-3601، TEST-4873، TEST-6966 و TEST-7037 (پاسخ) و TEST-4297 و TEST-8700 (پرسش). نسبی: TEST-3598 (پرسش دربارهٔ ترجیح راه‌حل، نه نسخه و کد حداقلی)؛ TEST-4884 (پاسخ داد، جایی که باید می‌پرسید)؛ TEST-9603 (پاسخ با استنباطی معقول، جایی که فرض باید گفته یا پرسیده می‌شد).

همهٔ «قبول»های دو طراحی advanced روی test پاسخ یا پرسش‌اند؛ هیچ پروندهٔ ارجاعی «قبول» نگرفت. تنها «قبول» Baseline یک ارجاع است، که با گرایشش به ارجاع جور است.

۷. چرا پرسش‌های doc2query ماند

این مقایسه پیش از دو اصلاح مرحلهٔ پاسخ انجام شد؛ بازیابی طراحی پیشین همان است. همان طراحی بدون پرسش‌های doc2query ۱۱ تصمیم از ۱۵ را درست گرفت، تنها یکی کمتر، و در ۱۴ پرونده دقیقاً همان تصمیم را داشت. پرسش‌های doc2query با دلیلی مشخص ماند: تنها تفاوت، تصمیم درست طراحی پیشین بود و از شواهدی آمد که فقط همین پرسش‌ها می‌یابند.

	بدون پرسش‌های doc2query	با پرسش‌ها (طراحی پیشین)
تصمیم درست	۱۱ از ۱۵	**۱۲ از ۱۵**
بخش‌های gold رسیده به مدل	۷۰٫۱٪	**۷۳٫۲٪**
صفحه‌های gold رسیده به مدل	۶۸٫۹٪	**۷۵٫۶٪**
داوری مستقل: قبول / نسبی / رد	۴ / ۴ / ۷	**۳ / ۴ / ۸**
هزینهٔ هر پرونده	~$ ۰٫۰۲۲	~$ ۰٫۰۲۱

تنها پروندهٔ متفاوت (DEV-5591): تغییرهای وضعیت نشست در نوار کناری برنامهٔ چندصفحه‌ای اعمال نمی‌شود. کاربر گزارش می‌دهد تغییرهایی که در نوار کناری ایجاد می‌کند، پس از رفتن به صفحهٔ دیگر و بازگشت از دست می‌رود. بدون پرسش‌های doc2query، از صفحهٔ «رفتار ویجت‌ها» در مستندات تنها مقدمهٔ کلی آن به مدل رسید؛ مدل یک توضیح دید و پاسخ داد. با پرسش‌ها، بخش «پایداری وضعیت ویجت‌ها» رسید: تغییر هویت ویجت آن را بازنشانی می‌کند، ویجتی که در هر اجرا رسم نشود باقی نمی‌ماند، و مقدار باید بین صفحه‌ها در وضعیت نشست ذخیره شود. مدل با دیدن چند توضیح رقیب که بدون کد کاربر از هم جدا نمی‌شوند، کد صفحه را خواست؛ برچسب پرونده همین تصمیم را می‌خواهد. این دقیقاً کاری است که پرسش‌های doc2query برای آن ساخته شدند: یافتن بخشی که کاربر نامش را نمی‌برد.

داور مستقل بازیابی طراحی پیشین را در هر ۱۵ پرونده برابر یا بهتر دانست. برای نمونه در DEV-10805 (وضعیت ویجت پس از افزودن run_every به fragment حفظ نمی‌شود)، ۸ از ۹ بخش برچسب‌خورده رسید در برابر ۵ از ۹، چون بدون پرسش‌ها صفحهٔ مستندات همان قابلیت جا افتاد. در دو پرونده، DEV-7305 (فراخوانی on_change در آغاز به متن text_area دسترسی ندارد و بعد مقدار قدیمی را می‌بیند) و DEV-4082 (فرم وضعیت نشست را تنها در هر دومین ارسال به‌روز می‌کند)، هم پاسخ بدون پرسش‌ها کمی روشن‌تر بود، که داور آن را بیشتر به نوسان اجرا به اجرای مدل نسبت داد.

محدودیت این انتخاب: یک پرونده از ۱۵ از نظر آماری تفاوت نیست (آزمون علامت روی پرونده‌های متفاوت، p = 1.0). اثر پرسش‌ها بر بازیابی هم به شمار بخش‌های افزوده بسته بود: با ۱۵ بخش بهتر شد و با ۵ یا ۱۰ بخش نه. هزینهٔ نگه‌داری هم دارد: بانک پرسش‌ها با هر تغییر مستندات باید دوباره ساخته شود. پس از دو اصلاح مرحلهٔ پاسخ، مقایسه با gpt-5.4-mini تکرار شد: با پرسش‌ها ۱۲ و بدون آن‌ها ۱۱ تصمیم درست. روی test، سود سطح بخش تکرار نشد: بدون پرسش‌ها ۵۲٫۶٪ بخش‌های gold در برابر ۴۵٫۰٪، هرچند پرسش‌ها صفحه‌های درست را بالاتر آوردند (۶-۳). گلوگاه reranker است: کاندیدهای تازه با شاهدهای خوب رقابت می‌کنند.

۸. روش‌های آزموده‌شده در هر مرحله

> در هر مرحلهٔ سامانه چند روش آزموده شد: ۱۰ روش پذیرفته شد و ۲۶ روش، هرکدام در چند گونه و در مجموع بیش از ۸۰ اجرا، به‌طور پایدار بهبود نداد. همهٔ اعداد با برچسب‌های بازبینی‌شده و روی همان ۱۵ پرونده است.

هر آزمایش تنها یک تغییر داشت. درصدها سهم بخش‌های gold رسیده به مدل‌اند؛ با ۸۱ بخش gold هر بخش حدود ۱٫۲٪ است و نوسان میان اجراها ۲ تا ۳ بخش، پس تنها تفاوتی پذیرفته شد که در چند تنظیم پایدار ماند. مرجع هر مقایسه طراحی آن مرحله در زمان آزمایش است و در بالای هر جدول آمده است؛ ردیف‌های پررنگ روش‌های پذیرفته‌اند.

۸-۱. آماده‌سازی پرسش

مرجع: گزارش پاک‌شده؛ یا طراحی نهایی در زمان آزمایش

روش	نتیجه (بخش‌های gold رسیده به مدل)	حکم
پاک‌سازی گزارش **حذف قالب GitHub از متن گزارش پیش از جست‌وجو.**	۵٫۷٪ ← ۲۷٫۱٪ به‌تنهایی	**پذیرفته**
تقسیم گزارش به جمله‌ها هر جمله جدا جست‌وجو و نتایج ادغام می‌شوند.	۳۹٫۹٪ در برابر ۳۹٫۶٪	بی‌اثر
تقسیم گزارش با مدل زبانی مدل گزارش را به چند تکهٔ مستقل می‌شکند.	۱۲٫۳٪ در برابر ۳۹٫۶٪	بدتر
تجزیه به پرسش‌های مفهومی مدل تا ۳ پرسش دربارهٔ سازوکارهای درگیر می‌نویسد و هر پرسش جدا جست‌وجو می‌شود؛ با ۳ پرامپت، ۱ تا ۳ پرسش، وزن کمتر برای پرسش‌ها، سهم ثابت یا افزودن بدون جایگزینی.	۴۸٫۲٪ تا ۶۱٫۷٪ در برابر ۶۱٫۸٪ بدون آن (و ۵۹٫۱٪ پیش از تکمیل بخش)؛ افزودن بدون جایگزینی ۶۷ تا ۷۰٪ در برابر ۷۰٫۱٪	بدتر یا بی‌اثر؛ یک فراخوانی و ۲ ثانیه بیشتر
دیدهای دیگر گزارش جست‌وجوی جداگانه برای عنوان، و برای شناسه‌های کد و متن خطا.	عنوان: بدون تغییر بخش‌ها، ترتیب بهتر؛ کد: یک پرونده بی‌شاهد ماند	پذیرفته نشد

۸-۲. جست‌وجو

مرجع: همان مرحله بدون این روش

روش	نتیجه (بخش‌های gold رسیده به مدل)	حکم
جای ثابت برای مستندات **۱۰ جا از ۱۵ کاندید برای مستندات.**	۳۶٫۲٪ به‌تنهایی؛ با پاک‌سازی ۳۹٫۶٪	**پذیرفته**
جست‌وجوی ترکیبی برداری و کلیدواژه‌ای (BM25) ادغام دو فهرست با RRF، جای جداگانه برای کلیدواژه، یا چند chunk کلیدواژه‌ای افزوده.	پیش از reranking ۴٪ بهتر (۴۳٫۵٪)؛ پس از reranking ۱۱٪ بدتر (۴۸٫۲٪ در برابر ۵۹٫۱٪، و ۵۰٫۴٪ در برابر ۶۱٫۸٪)	بدتر پس از reranking

روش	نتیجه (بخش‌های gold رسیده به مدل)	حکم
مدل Embedding بزرگ‌تر text-embedding-3-large به‌تنهایی یا ادغام‌شده با مدل کوچک، با وزن‌های ۰٫۳ تا ۱.	۵۴٫۴٪ به‌تنهایی؛ ۵۸٫۵٪ تا ۵۹٫۶٪ با ادغام؛ در برابر ۶۱٫۸٪	بدتر
خوشه‌بندی و routing موضوعی chunkها در خوشه‌های برداری یا موضوع‌های برچسب‌خورده با مدل گروه‌بندی و جست‌وجو به آن‌ها محدود یا متمایل می‌شود.	خوشه‌ها ۴ تا ۶٪ بدتر در هر طراحی؛ محدودکردن به موضوع‌ها پرونده از دست داد؛ تمایل در یک شدت ۷۱٫۷٪ و در شدت دیگر ۶۷٫۸٪ در برابر ۷۰٫۱٪	ناپایدار
کاندیدهای بیشتر ۲۰ کاندید به‌جای ۱۵، یا ۸ جای مستندات به‌جای ۱۰.	۲۰ کاندید بدون تغییر؛ ۸ جا ۶۴٫۰٪ در برابر ۶۱٫۸٪ با صفحه‌های gold کمتر	در حد نوسان
پرسش‌های doc2query (doc2query) **برای هر بخش مستندات ۵ پرسش به زبان کاربر؛ گزارش با پرسش‌ها هم مقایسه می‌شود.**	۱۵ بخش: ۷۳٫۲٪ در برابر ۷۰٫۱٪؛ ۵ و ۱۰ بخش: ۶۶٫۰٪ و ۶۷٫۳٪	**پذیرفته با ۱۵ بخش (فصل ۷)**
پالایش پرسش‌ها، chunk نزدیک‌تر به پرسش، پرسش‌های مدل قوی‌تر حذف پرسش‌هایی که به بخش خود اشاره نمی‌کنند؛ انتخاب chunk با پرسش؛ نوشتن پرسش‌ها با gpt-4.1-mini.	۶۵٫۸٪ تا ۶۷٫۶٪ در برابر ۶۶٫۰٪ تا ۶۷٫۳٪ بدون این‌ها	بی‌اثر

۸-۳. chunking

مرجع: پنجره‌های ثابت ۵۱۲ توکنی با همان بازیابی

روش	نتیجه (بخش‌های gold رسیده به مدل)	حکم
chunking بر پایهٔ ساختار chunkها بر پایهٔ سرفصل‌ها و بخش‌ها؛ در دو پیاده‌سازی، با یا بدون افزودن chunkهای همسایه.	۵۸٫۲٪ و ۴۴٫۶٪ در برابر ۷۰٫۱٪؛ با همسایه‌ها ۶۵٫۶٪ و ۵۲٫۹٪	بدتر
تکمیل بخش **هر chunk برگزیدهٔ مستندات پس از reranking تا کل بخش‌هایش گسترش می‌یابد.**	۵ تا ۸٪ بهتر در هر طراحی (۵۵٫۹٪ ← ۶۱٫۸٪؛ با ۸ chunk ۶۰٫۰٪ ← ۶۶٫۷٪)؛ شاهد برای هر ۱۵ پرونده	**پذیرفته**
تکمیل بخش با برش همان، به‌علاوهٔ حذف تکهٔ باقی‌مانده از بخش قبلی.	۶۴٫۳٪ ولی یک پرونده بی‌شاهد ماند: متن بریده‌شده خود شاهد بود	پذیرفته نشد

۸-۴. reranking

مرجع: reranking طراحی نهایی

روش	نتیجه (بخش‌های gold رسیده به مدل)	حکم
آگاه از نسخه نسخهٔ کاربر و برچسب نسخهٔ هر کاندید به reranker داده شد، با قاعدهٔ «منبع مناسب نسخهٔ کاربر را ترجیح بده».	۷۳٫۲٪ ← ۷۱٫۱٪؛ gold در رتبهٔ ۱: ۸۰٪ ← ۵۳٪؛ تصمیم‌ها با gpt-5-mini: ۴ پرونده جابه‌جا، بدون سود خالص	بی‌اثر

روش	نتیجه (بخش‌های gold رسیده به مدل)	حکم
یادداشت‌های انتشار جدیدتر دو یادداشت انتشارِ جدیدتر از نسخهٔ کاربر، نزدیک‌ترین به گزارش، به کاندیدها اضافه شد.	۷۳٫۲٪ ← ۶۸٫۲٪؛ مستندات لینک‌شده بیرون رانده شد	بدتر
reranking با مدل زبانی **یک فراخوانی gpt-4o-mini کاندیدها را رتبه می‌دهد.**	۳۹٫۶٪ ← ۵۹٫۱٪؛ حذف آن: ۷۰٫۱٪ ← ۶۴٫۳٪ و شاهد اول در ۳ پرونده به‌جای ۱۱	**پذیرفته**
کمینهٔ مستندات در نتیجه **دست‌کم ۴ یا ۵ chunk از مستندات در chunkهای نهایی.**	۶۳٫۵٪ و ۶۵٫۱٪ در برابر ۶۱٫۸٪؛ با ۸ chunk ۷۰٫۱٪	**پذیرفته (۵ chunk)**
پنجرهٔ نمایش دیگر ۴۰۰ نویسهٔ نخست، ۶۰۰ یا ۸۰۰ نویسه، فهرست سرفصل‌ها یا عنوان صفحه در کنار هر کاندید.	۶۰٫۰٪ تا ۷۰٫۹٪؛ ترتیب برابر یا بدتر؛ فهرست سرفصل‌ها ۵٪ بدتر	پذیرفته نشد
reranker قوی‌تر gpt-4.1-mini به‌جای gpt-4o-mini.	۶۱٫۴٪ در برابر ۶۱٫۸٪؛ با پرسش‌های doc2query ۷۰٫۲٪ در برابر ۶۷٫۳٪ اما شاهد اول در ۸ پرونده به‌جای ۱۲	بی‌اثر، ترتیب بدتر
پرامپت «توضیحی» مقدم داشتن متنی که علت یا راه‌حل را توضیح می‌دهد، حتی با نام سازوکاری دیگر.	۶۹٫۹٪ تا ۷۱٫۲٪؛ شاهد اول در ۹ پرونده به‌جای ۱۱ تا ۱۲	در حد نوسان، ترتیب بدتر
ادغام دو رتبه‌بندی دو reranking با پرامپت موضوعی و توضیحی، ادغام با RRF، به‌نوبت یا ۴ + ۴.	۶۹٫۵٪ تا ۷۱٫۲٪	پایدار ولی بی‌اثر؛ دو فراخوانی
ترکیب با رتبهٔ جست‌وجو میانگین وزنی رتبهٔ reranker و رتبهٔ جست‌وجو.	۱ تا ۲۱٪ بدتر در همهٔ وزن‌ها	بدتر
کمک به کاندیدهای یافته با پرسش نمایش پرسش منطبق، پنجره با واژه‌های پرسش، ترتیب درهم، یا رزرو جا.	۱ تا ۱۸٪ بدتر	بدتر
بدون reranker، با امتیاز جست‌وجو ۸ chunk بر پایهٔ شباهت، یا ۴ از جست‌وجو و ۴ از پرسش‌ها.	۶۰٫۴٪ و ۲۹٫۳٪	بسیار بدتر

۸-۵. بودجه و حلقه

مرجع: طراحی در زمان آزمایش

روش	نتیجه (بخش‌های gold رسیده به مدل)	حکم
۸ chunk به‌جای ۶ **بودجهٔ ۴٬۳۰۰ به‌جای ۳٬۲۰۰ توکن.**	بدون تکمیل بخش بی‌اثر (۵۵٫۹٪)؛ با آن و کمینهٔ مستندات ۷۰٫۱٪	**پذیرفته**
حلقهٔ اصلاحی داوری کفایت شواهد با یکی از سه پرامپت و جست‌وجوی دوباره.	۵۸٫۷٪، ۶۳٫۵٪ و ۶۲٫۵٪ در برابر ۶۱٫۸٪؛ ۱ تا ۶ فراخوانی بیشتر برای هر پرونده	در حد نوسان

۸-۶. مرحلهٔ پاسخ

مرجع: تصمیم‌های درست از ۱۵ روی همان شواهد؛ «پیشین» یعنی طراحی پیش از دو اصلاح (۱۲ از ۱۵)

روش	نتیجه (بخش‌های gold رسیده به مدل)	حکم
پاسخ‌گوی ساده یک فراخوانی gpt-4o-mini با پرامپت Baseline.	۵ تا ۷: تقریباً همه را پاسخ می‌دهد	بدتر
انتخاب اقدام توسط خود مدل مدل با یک پرامپت سیاست، خودش پاسخ، پرسش یا ارجاع را انتخاب می‌کند.	۱۰	بدتر
ارزیابی ساختاریافته و routing در پایتون **مدل ارزیابی می‌نویسد و یک قاعدهٔ پایتون اقدام را برمی‌گزیند.**	۱۲ (۱۱ بدون پرسش‌های doc2query؛ ۹ با chunk ۶؛ ۱۰ با دو رتبه‌بندی)	**پذیرفته**
یادداشت نسخه روی شواهد **هر منبع می‌گوید چه نسخه‌ای را توصیف می‌کند، در مقایسه با نسخهٔ کاربر، و چگونه باید به کار رود (فصل ۱۰).**	همراه با پرسش کامل: ۱۲؛ ارجاع ۱ → ۲ از ۳؛ داور ۸ → ۹ «قبول»	**پذیرفته**
پرسش کامل **پرسش همهٔ کمبودهای اطلاعاتیِ مهم را در یک پیام می‌خواهد، نه فقط اولی را (فصل ۱۰).**	تصمیم‌ها تغییر نمی‌کند؛ پرسش‌های ناقص کامل شد	**پذیرفته**
مدل ارزان‌تر: gpt-5-mini همان درخواست بستهٔ پاسخ، با مدلی حدود ۲٫۵ برابر ارزان‌تر (فصل ۱۱).	۱۰ و با دو اصلاح ۱۱؛ در هیچ اجرایی ارجاع نداد	پذیرفته نشد
قاعدهٔ ارجاع در پرامپت (controlled_v3) ثبت بررسی داخلی وقتی بازتولید کامل است، و پاسخ‌ندادن به علامتی که مستندات فقط بخشی از آن را توضیح می‌دهد.	با gpt-5-mini: دو پاسخ درست به پرسش تبدیل شد و هیچ ارجاعی رخ نداد	بدتر
سه قاعدهٔ پیشنهادی داور (controlled_v4) اطلاعاتِ گفته‌شده در گزارش کمبود نیست؛ ارجاع وقتی کنترل‌ها کامل است؛ سقف طول پاسخ.	با gpt-5-mini: هیچ تصمیمی تغییر نکرد؛ میانهٔ طول پاسخ ۱۷۵ → ۴۷ واژه	بی‌اثر

الگوی مشترک: روش‌هایی که جست‌وجو را بهتر کردند (ترکیب کلیدواژه‌ای، تجزیه به پرسش‌های مفهومی، خوشه‌ها، پرسش‌های doc2query با شمار کم) اغلب پس از reranking سود خود را از دست دادند: کاندیدهای تازه به نظر reranker مرتبط بودند ولی شاهد اصلی نبودند. روش‌هایی که داوری reranker را دور زدند یا رقیق کردند همیشه بدتر شدند، و چند روش ترتیب را بهتر کردند ولی بخش gold کمتری رساندند. بیشترین سود از روش‌هایی آمد که شواهدِ برگزیده را **کامل‌تر** کردند (تکمیل بخش و بودجهٔ بیشتر همراه با آن)، نه از روش‌هایی که کاندیدهای بیشتری آوردند.

۸-۷. آزمایش‌های مرحلهٔ پاسخ با شواهد منتخب

این آزمایش‌ها پیش از اتصال به بازیابی، با **شواهد برچسب‌خورده** (بخش‌های gold و منابع منتخب) انجام شد، نه با خروجی بازیابی؛ هدف جدا کردن کیفیت مرحلهٔ پاسخ از کیفیت بازیابی بود. پس اعدادشان با نتایج پایپ‌لاین (فصل ۶) قابل مقایسهٔ مستقیم نیستند، و هر بار پرامپت، قالب خروجی یا اندازهٔ نمونه هم تغییر کرده است.

آزمایش	نتیجه	درس
شواهد gold به‌اضافهٔ نتایج بازیابی، gpt-4o-mini	۵ از ۱۵	شواهد بیشتر به‌تنهایی راه‌حل نبود
حذف یا تغییر بازبین و پرامپت (gpt-4o-mini)	۲ تا ۶ از ۱۵	قرارداد بازبین و پرامپت اقدام را عوض می‌کرد، بی‌آنکه درستی محتوا ثابت شود
شش بخش منتخب دستی	۶ از ۱۵	انتخاب بهتر شواهد، رفتار پاسخ و بازبین را خودکار درست نکرد
بازبین جدا، روی پیش‌نویس‌های ثابت	رخدادهای نامعتبر ۶ ← ۰	ساختار بهتر شد، خطای معنایی ماند؛ پذیرفته نشد
طراحی چندمرحله‌ای با بازبین و اصلاح	۸۲ فراخوانی؛ روی پنج پرونده بدتر	مرحلهٔ بیشتر بهتر نبود؛ پذیرفته نشد
مدل کوچک‌تر در برابر gpt-5.4-mini (سه پرونده)	۱ از ۳ در برابر ۳ از ۳	نشانهٔ مثبت روی نمونهٔ کوچک، نه اثبات کلی؛ روی ۱۵ پرونده ۹ از ۱۵
مثال‌های نمونه در پرامپت (few-shot)	۹ از ۱۵، بی‌تغییر	سود خالصی نداشت
تلاش استدلالی زیاد در برابر متوسط	متغیر روی سه پرونده؛ دو برابر هزینه	استدلال بیشتر تضمین نبود
انتخاب اقدام توسط خود مدل (policy v3)	۹ از ۱۵ (۵ / ۲ / ۲)	مرز پرسش و ارجاع با واژه‌پردازی پرامپت درست نشد
ارزیابی مدل و تصمیم در کد (controlled_v2، انتخاب‌شده)	**۱۱ از ۱۵ (۵ / ۳ / ۳)**	کمبود قابل‌پاسخ صریحاً بر پاسخ و ارجاع مقدم شد

هزینه: کنترلر کد محلی است و هیچ توکنی مصرف نمی‌کند؛ هر دو اجرای کامل (policy v3 و controlled_v2) ۱۵ فراخوانی داشتند. هزینهٔ تخمینی از ۰٫۲۱۶ به ۰٫۲۶۵ دلار رسید (حدود ۲۳٪)؛ توکن ورودی ۴۷,۸۵۹ ← ۵۷,۲۷۶ و خروجی (همراه استدلال) ۳۹,۹۳۴ ← ۴۹,۲۵۵، و حدود ۸۶٪ این افزایش از توکن خروجی است. چون پرامپت و قالب خروجی هم عوض شده بود، نه بهبود و نه افزایش هزینه را نمی‌توان فقط به کنترلر نسبت داد.

خطاهایی که این مسیر را شکل داد: پاسخ زودهنگام بر پایهٔ پیش‌فرضی دیده‌نشده (مثلاً مقداردهی‌ای که در کد نبود)؛ ارجاع زودهنگام با وجود یک پرسش مفید (مدل نبودن نسخه را دیده بود و باز ارجاع داد)؛ خطاهای بازبین (پرسش دوباره دربارهٔ اطلاعاتِ داده‌شده، یا پذیرش ادعای بی‌پشتوانه)؛ و تعمیم مستندات امروز به نسخه‌های قدیمی. نمونهٔ ماندگارش DEV-3903 است: مدل مقداری را در کد فرض کرد که در گزارش نبود.

۹. تحلیل خطا با داور LLM

داوری در سه دور انجام شد: دور نخست خطاهای طراحی پیشین را در چهار الگو دسته‌بندی کرد و پایهٔ اصلاح‌های فصل ۱۰ شد؛ دور دوم سه طراحی را روی همان ۱۵ پروندهٔ dev مقایسه کرد؛ و دور سوم، سه اجرای test را.

۹-۱. روش

- **داور:** Claude Opus 5.5، مدلی از خانواده‌ای جز مدل پاسخ، که بیرون از سامانه و از طریق رابط گفت‌وگو به کار رفت، نه از راه API پروژه؛ از این رو هزینه‌ای از بودجهٔ تیم نداشت. هر پرونده جداگانه داوری شد.
- **معیار و پرامپت منتشرشده:** `docs/evaluation/judge_prompt.md` و متن دقیق پرامپت در `configs/prompts/judge_case_system.txt`.
- **آنچه با کد سنجیده می‌شود،** نه با داور: Recall@k، دقت به تفکیک دسته، هزینه و زمان.

> **داوری و «تصمیم درست» دو سنجهٔ جدا هستند:** تصمیم درست فقط تطبیق تصمیم با برچسب است؛ داوری کیفیت کل پاسخ را می‌سنجد. پروندهٔ با تصمیم درست و پرسش ضعیف می‌تواند «نسبی» باشد، و تصمیم نادرستِ تاحدی قابل دفاع هم «نسبی».

پرامپت داور، خلاصه: برای هر پرونده، داور گزارش، تصمیم ذخیره‌شده، متن دقیق شواهدی که مدل دید و اینکه کدام استناد شد، ارزیابی مدل و routing، و فایل ارزیاب را می‌بیند (تصمیم‌های قابل قبول، استدلال مرجع، ادعاهای ممنوع، اطلاعات لازم برای پرسش، بخش‌های gold و مواد «فقط برای داور»: کامنت‌ها و یادداشت‌های انتشار بعدی که از سامانه پنهان مانده‌اند). قواعد: فایل ارزیاب مرجع است و چند پاسخ می‌تواند قابل دفاع باشد؛ تصمیم ذخیره‌شده داوری می‌شود، نه فقط متن؛ هر ادعا فقط با متن شواهد همان پرونده پشتیبانی می‌شود؛ پاسخ‌ندادن خودبه‌خود امن نیست. خروجی: امتیاز ۰ تا ۲ برای کیفیت شواهد، تصمیم، درستی عملیاتی، پاسخ کاربر و خلاصهٔ نگه‌دارنده؛ فهرست ادعاهای بی‌پشتوانه و ممنوع؛ تحلیل خطا؛ و حکم قبول، نسبی یا رد.

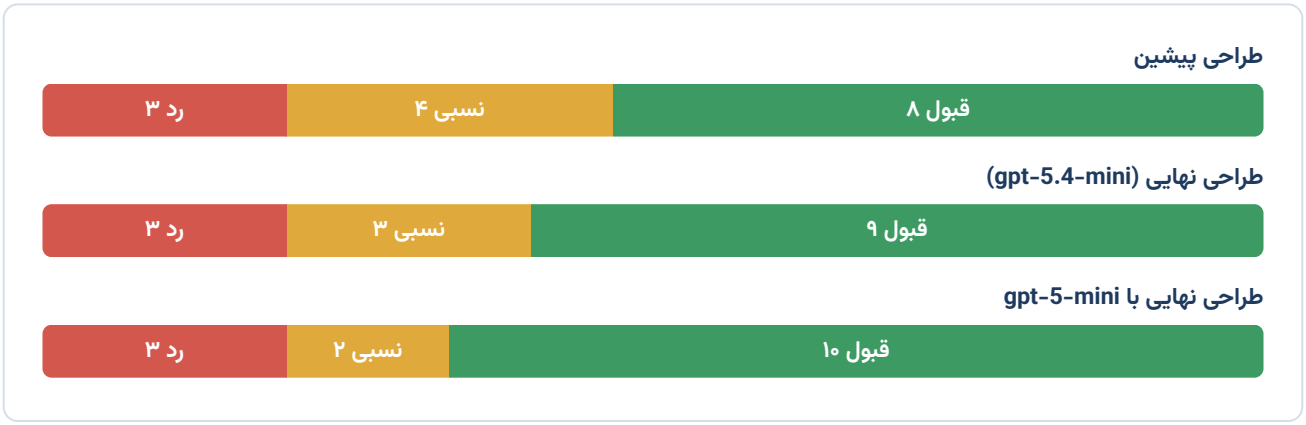
۹-۲. دور نخست: خطاهای طراحی پیشین

طراحی پیشین ۸ «قبول»، ۴ «نسبی» و ۳ «رد» گرفت. هفت پروندهٔ نسبی و رد در چهار الگو جمع می‌شوند:

الگو	پرونده‌ها	آنچه داور دید
نسخه بررسی نمی‌شود	DEV-4325، DEV-4989، DEV-4338، DEV-3903، DEV-3585	مستندات امروز (نسخهٔ ۱٫۶۵) به گزارش‌های نسخه‌های ۰٫۸۴ تا ۱٫۵۹ تعمیم داده شد؛ یادداشت انتشار به‌عنوان علت به کار رفت
ارجاع ضعیف	DEV-16388، DEV-6166، DEV-3585	یک جملهٔ مستندات توضیح کامل فرض شد؛ گزارش دارای بازتولید کامل، پرسش گرفت؛ ارجاع بدون بررسی نسخه

الگو	پرونده‌ها	آنچه داور دید
پرسش ناقص	DEV-5591، DEV-3903، DEV-6166	فقط یکی از اطلاعات لازم خواسته شد (مثلاً کد، بدون نسخه و ترتیب گام‌ها)
بخش توضیح‌دهندهٔ سازوکار بازیابی نشد	DEV-4325، DEV-5604، DEV-16388، DEV-7305، DEV-6166	بخشی که علت را توضیح می‌دهد در شواهد نبود

۹-۳. دور دوم: سه طراحی



شکل ۶ — داوری‌ها روی ۱۵ پروندهٔ توسعه؛ تصمیم‌های درست به ترتیب ۱۲، ۱۲ و ۱۱.

پرونده	پیشین	نهایی	نهایی، gpt-5-mini	تفاوت
DEV-4338 رفتار ناسازگار وضعیت نشست با ویجت‌ها (نسخه‌های ۰٫۸۹ تا ۱٫۵)	نسبی	قبول	قبول	یادداشت انتشار دیگر به‌عنوان علت به کار نرفت
DEV-16388 حذف کلید یک ویجت از وضعیت نشست، مقدار کهنه را روی صفحه باقی می‌گذارد (نسخهٔ ۱٫۵۹)	رد	قبول	رد	با gpt-5.4-mini ارجاع داد و ناهمخوانی را ثبت کرد
DEV-3585 فراخوانی on_click در فرم پیش از کلیک اجرا می‌شود (نسخهٔ ۰٫۸۴)	رد	نسبی	نسبی	به‌جای ارجاع بی‌مورد، پرسید
DEV-5591 تغییرهای وضعیت نشست در نوار کناری برنامهٔ چندصفحه‌ای اعمال نمی‌شود	نسبی	نسبی	قبول	با gpt-5-mini تنها اجرایی که نسخه، کد و ساختار را با هم خواست
DEV-3903 تنظیم مقدار ویجت از راه وضعیت نشست پس از مقداردهی اولیه کار نمی‌کند (نسخهٔ ۱٫۰)	نسبی	رد	قبول	gpt-5.4-mini پاسخ داد؛ gpt-5-mini هر دو بررسی لازم را پرسید
DEV-5604 text_area درون expander مقدار وضعیت نشست را نمی‌گیرد (نسخهٔ ۱٫۱۳)	قبول	رد	قبول	gpt-5.4-mini هیچ کمبودی ثبت نکرد و ارجاع داد

پرونده	پیشین	نهایی	نهایی، gpt-5-mini	تفاوت
DEV-10805 وضعیت ویجت پس از افزودن run_every به fragment حفظ نمی‌شود	قبول	قبول	نسبی	gpt-5-mini با وجود کنترل‌های کامل، ارجاع نداد
DEV-4325 multiselect با فراخوانی تغییر، تنها یک گزینه را می‌پذیرد	نسبی	نسبی	رد	gpt-5-mini چیزی را پرسید که گزارش گفته بود

یادداشت نسخه کار کرد: خطای «یادداشت انتشار به‌عنوان علت» در DEV-4338 با هر دو مدل از بین رفت. پرسش کامل تنها وقتی اثر دارد که مدل چند کمبود ثبت کند: با gpt-5-mini بهترین پرسش‌ها را ساخت، اما gpt-5.4-mini در DEV-5591 و DEV-3903 فقط یک کمبود ثبت کرد. پرونده‌های DEV-6166 (هر سه طراحی رد) و ضعف ارجاع در gpt-5-mini در این پروژه حل نشد.

۹-۴. دور سوم: مجموعهٔ test

هر سه اجرای test را داور مستقل بیرونی داوری کرد (۴۵ پرونده). طراحی نهایی جداگانه یک‌بار دیگر هم، در جلسه‌ای که از پروژه آگاه بود، داوری شد؛ دو داور در ۱۳ پرونده از ۱۵ هم‌نظر بودند و هر دو اختلاف میان «نسبی» و «رد» بود، که نشان می‌دهد داوری‌ها وابسته به یک داور نیستند. داوری داور بیرونی گزارش می‌شود.

مشکل کیفی طراحی نهایی روی test	پرونده‌ها
به‌کارگیری مستندات امروز (مثلاً قاعدهٔ هویت ویجت در 1.55) برای نسخه‌های قدیمی	TEST-3598، TEST-7649
خوانش نادرست کد کاربر	TEST-3921، TEST-7037
اعلام زودهنگام «هیچ پرسش مفیدی نیست» و ارجاع، بدون آزمون ساده‌ای که کاربر می‌تواند انجام دهد	TEST-3921، TEST-4297، TEST-4884
یادداشت انتشار به‌عنوان راه‌حل، برای علامتی دیگر	TEST-9841
نادیده گرفتن آنچه گزارش گفته بود	TEST-7649، TEST-8700
شواهد توضیح‌دهنده بازیابی نشد	TEST-3921، TEST-7037، TEST-5305

همان خانواده‌های خطای dev دوباره دیده شد؛ چرایی آن در ۱۰-۳ آمده است. این یافته‌ها برای گزارش و کار آینده‌اند، نه برای تغییر طراحی پس از دیدن test.

۱۰. اصلاح‌ها: از یافته‌های داور تا طراحی نهایی

از چهار الگوی خطا، دو الگو با دو اصلاح در مرحلهٔ پاسخ رفع شد و در طراحی نهایی ماند. برای ارجاع، بررسی داده‌ها نشان داد مشکل در قضاوت مدل است نه در routing، و دو نسخهٔ پرامپت آزموده شد که بهبود نداد.

۱۰-۱. چهار الگو و آنچه انجام شد

از الگوی خطا تا تصمیم

پرامپت بستهٔ پاسخ (controlled_v2) در طراحی نهایی بدون تغییر ماند؛ اصلاح‌ها پیش و پس از فراخوانی مدل‌اند

پذیرفته

در طراحی نهایی

نسخه — پذیرفته

یادداشت نسخه: پیش از فراخوانی مدل، روی هر منبع دو یادداشت نوشته می‌شود: چه نسخه‌ای را توصیف می‌کند در مقایسه با نسخهٔ کاربر («این انتشار از نسخهٔ شما جدیدتر است، پس این تغییر در آن نیست»)، و چگونه باید به کار رود («یادداشت انتشار تغییر را نشان می‌دهد، نه علت را»). بستهٔ پاسخ از قبل این دو فیلد را می‌خواند؛ داده‌های ما خالی‌شان گذاشته بود.

پرسش — پذیرفته

پرسش کامل: مدل در ارزیابی خود تا سه کمبود اطلاعاتی و برای هر کدام یک پرسش می‌نویسد، اما کد routing فقط پرسشِ اولی را به کاربر می‌فرستاد. اکنون پس از تصمیم، همهٔ پرسش‌های مهم در یک فهرست شماره‌دار فرستاده می‌شود. بدون فراخوانی تازهٔ مدل و بدون تغییر تصمیم.

آزموده و پذیرفته‌نشده، یا گام بعدی

با دلیل

ارجاع — پذیرفته نشد

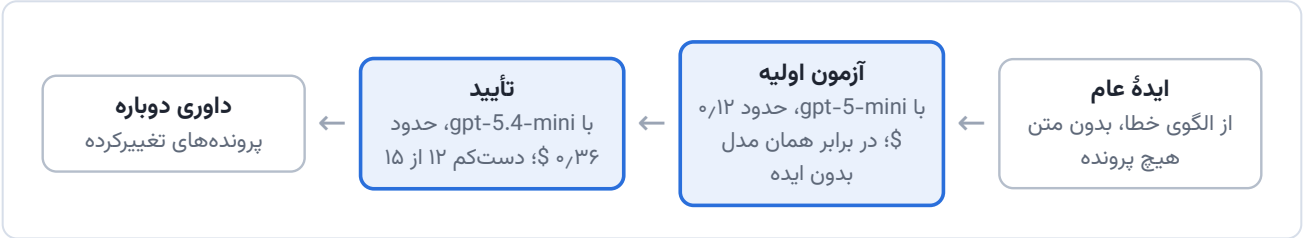
قاعده در پرامپت (controlled_v3 و controlled_v4): بررسی فیلدهای ارزیابی نشان داد در DEV-16388 و DEV-6166 مدل اصلاً «بررسی داخلی» ثبت نکرده بود؛ پس تغییر قاعدهٔ routing کمکی نمی‌کرد. دو نسخهٔ پرامپت با قاعدهٔ ارجاع آزموده شد؛ هیچ‌کدام ارجاع را بهتر نکرد.

سازوکار — گام بعدی

بازیابی بخش توضیح‌دهندهٔ سازوکار: یک داور دوم بله/خیر برای هر کاندید پس از reranking؛ بزرگ‌ترین تغییر، و در گام‌های بعدی (۱۵-۲) آمده است.

شکل ۷ — سرانجام هر الگوی خطا.

۱۰-۲. روند آزمودن: آزمون اولیهٔ ارزان، تأیید با مدل اصلی



شکل ۸ — هر ایده ابتدا با مدل ارزان آزمون اولیه و تنها ایده‌های امیدوارکننده با مدل اصلی تأیید شد.

- **یادداشت نسخه، آزمون اولیه:** با gpt-5-mini از ۱۰ به ۱۱ از ۱۵؛ DEV-5604 و DEV-3903 درست پرسیده شدند. یک خطای تازه (DEV-4325) نشان داد یادداشت مستندات حتی وقتی کاربر نسخه‌ای نگفته بود به پرسیدن نسخه وامی‌داشت؛ این یادداشت برای گزارش‌های بدون نسخه برداشته شد.
- **هر دو اصلاح، تأیید:** با gpt-5.4-mini همان ۱۲ از ۱۵، با ترکیبی متفاوت: DEV-16388 درست ارجاع شد و DEV-3585 درست پرسیده شد، اما DEV-5604 و DEV-3903 نادرست شدند. چون تصمیم‌ها برابر بود، کیفیت پاسخ‌ها (داوری ۹ در برابر ۸) و بهبود ارجاع تعیین‌کننده شد.
- **قاعدهٔ ارجاع (controlled_v3):** با gpt-5-mini دو پاسخ درست به پرسش تبدیل شد و هیچ ارجاعی رخ نداد؛ رد شد.
- **سه قاعدهٔ داور (controlled_v4):** اطلاعاتِ گفته‌شده در گزارش کمبود نیست؛ ارجاع وقتی کنترل‌ها کامل است؛ سقف طول پاسخ. با gpt-5-mini هیچ تصمیمی تغییر نکرد، اما میانهٔ طول پاسخ از ۱۷۵ به ۴۷ واژه رسید. این قواعد فقط با gpt-5-mini آزموده شد.
- **پایداری اتصال:** درخواست‌های طولانی چند بار با «Connection error» قطع شدند؛ اکنون مرحلهٔ پاسخ یک قطع اتصال را یک‌بار دوباره تلاش می‌کند، ولی هرگز پاسخ نامعتبر، توقف بودجه یا پاسخ ردشده را تکرار نمی‌کند.

> **پرهیز از نشت:** همهٔ قاعده‌ها از الگوی کلی نوشته شدند و نام هیچ API، علامت یا پرونده‌ای در آن‌ها نیست؛ آزمونی خودکار بررسی می‌کند که هیچ شناسه یا عنوان پروندهٔ توسعه و آزمون در پرامپت نسخه‌های تازه نباشد. با این حال چون اصلاح‌ها از خطاهای مجموعهٔ توسعه آمده‌اند، نتیجه روی همان مجموعه خوش‌بینانه است؛ سنجش منصفانه اجرای یک‌بارهٔ مجموعهٔ آزمون است.

۱۰-۳. اثر اصلاح‌ها، و آنچه پس از داوری آزموده شد

انتساب: از چهار پرونده‌ای که با دو اصلاح جابه‌جا شدند (۱۰-۲)، اثر روشن و قابل انتساب فقط در DEV-4338 دیده شد: داور نوشت خطای «یادداشت انتشار به‌عنوان علت» از بین رفته است؛ بقیه در حد نوسان است. یادداشت نسخه قاعده‌محور است: یک تابع پایتون بدون مدل که از نوع، نسخه و تاریخ منبع و نسخهٔ گزارش‌شده، اعداد نسخه را مقایسه می‌کند و دو فیلد version_applicability و usage_constraint را پر می‌کند که بستهٔ پاسخ از قبل به مدل نشان می‌داد.

چرا الگوها روی test ماند: پیکره فقط مستندات امروز (1.65) را دارد و گزارش‌ها از 0.84 تا 1.59 هستند؛ پس مدل قاعده‌های امروز را به نسخهٔ قدیمی تعمیم می‌دهد (مثلاً قاعدهٔ هویت ویجت از 1.55 برای گزارشی روی 1.28) یا یادداشت انتشار جدیدتر را علت می‌گیرد. یادداشت نسخه توصیه است، نه اجبار: در TEST-9841 کنار همان منبع نوشته بود «تغییر را نشان می‌دهد، نه علت را»، و مدل باز هم آن را علت گرفت. اصلاح‌ها از خطاهای dev آمده بودند و بخشی از اثرشان مخصوص همان پرونده‌ها بود؛ خطای پرسش در برابر ارجاع هم به نسخه ربطی ندارد و قضاوت مدل است.

آزموده پس از داوری، بی‌اثر (افزون بر controlled_v3 و controlled_v4؛ جزئیات در ۸-۴)	نتیجه
reranking آگاه از نسخه	بخش‌های gold ۷۳٫۲٪ ← ۷۱٫۱٪؛ gold در رتبهٔ ۱: ۸۰٪ ← ۵۳٪
یادداشت‌های انتشار جدیدتر در کاندیدها	۷۳٫۲٪ ← ۶۸٫۲٪

آزموده پس از داوری، بی‌اثر (افزون بر controlled_v3 و controlled_v4؛ جزئیات در ۸–۴)	نتیجه
جابه‌جایی قاعده‌های routing (ارجاع پیش از پرسش)	کنار گذاشته شد؛ مدل در آن پرونده‌ها اصلاً «بررسی داخلی» ثبت نکرده بود

راه‌حل واقعی، مستندات نسخه‌دار و فیلتر بر اساس نسخهٔ کاربر است؛ یا قاعده‌ای در کد که پاسخ مبتنی بر یادداشت انتشار را فقط با تطابق دقیق شمارهٔ issue یا علامت بپذیرد.

۱۱. انتخاب مدل پاسخ: gpt-5.4-mini یا gpt-5-mini

طراحی نهایی پیش از test با gpt-5.4-mini انتخاب شد، چون gpt-5-mini در هیچ اجرایی روی dev ارجاع نداد. روی test، gpt-5-mini کمی بهتر بود؛ این نتیجه گزارش می‌شود، اما انتخاب پس از دیدن test عوض نمی‌شود.

طراحی نهایی با…	dev ،gpt-5.4-mini	dev ،gpt-5-mini	test ،gpt-5.4-mini	test ،gpt-5-mini
تصمیم درست	۱۲	۱۱	۶	۸
پاسخ / پرسش / ارجاع	۶ / ۴ / ۲	۵ / ۶ / ۰	۴ / ۲ / ۰	۴ / ۴ / ۰
داوری: قبول / نسبی / رد	۹ / ۳ / ۳	۱۰ / ۲ / ۳	۵ / ۲ / ۸	۶ / ۳ / ۶
هزینه / زمان هر پرونده	۰٫۰۲۴ $ / ۲۰ ث	۰٫۰۰۹ $ / ۳۰ ث	۰٫۰۲۲ $	۰٫۰۰۹ $

- **کیفیت نوشتن یکسان است:** روی test، در ۷ پرونده‌ای که دو مدل تصمیم یکسان گرفتند، هر کدام در ۲ پرونده پاسخ بهتری نوشت و ۳ پرونده برابر بود. برتری gpt-5-mini روی test از تصمیم‌هاست: جایی پرسید که gpt-5.4-mini بی‌دلیل ارجاع داده بود.
- **نقاط قوت هر مدل:** gpt-5.4-mini شواهد را بهتر به کار می‌برد (۱٫۴۷ در برابر ۱٫۱۳ از ۲، به نظر داور)؛ gpt-5-mini پاسخ‌های خواناتر و پرسش‌های کامل‌تری دارد (۱٫۰۰ در برابر ۰٫۷۳).
- **ضعف مشترک:** هیچ‌کدام روی test پرونده‌های ارجاع را درست نگرفت؛ gpt-5-mini در هیچ اجرایی، روی dev و test، ارجاع نداد.
- **توصیه برای ادامه:** gpt-5-mini با یک‌سوم هزینه، جایگزینی جدی است؛ با ۱۵ پرونده، تفاوت دو مدل در هیچ جهتی قطعی نیست.

۱۲. پیگیری پرونده (مسئلهٔ ۲)

پیگیری چندنوبتی پرونده یک گراف LangGraph برای هر پرونده است، با رهگیر محلی SQLite، توقف برای تأیید انسانی و تضمین‌هایی که در کد اعمال می‌شوند، نه در متن مدل.



شکل ۹ — جریان هر نوبت پرونده.

سناریوی خواسته‌شده	رفتار سامانه	آزمون خودکار
تأیید، ویرایش یا رد توسط نگه‌دارنده	تأیید دقیقاً همان متن را منتشر می‌کند؛ ویرایش متن ویرایش‌شده را؛ رد هیچ تغییری نمی‌دهد	دارد
تأیید وابسته به همان پرونده و همان پیشنهاد	تأیید باید شناسهٔ پیشنهاد را نام ببرد؛ پرونده‌ها هرگز مخلوط نمی‌شوند	دارد
تغییر پرونده پیش از اجرا یا اصلاح گفتهٔ کاربر	اگر کاربر پس از پیشنهاد پیام تازه بدهد، پیشنهاد کهنه است و منتشر نمی‌شود	دارد
توقف هنگام انتظار برای تأیید	پرونده پس از راه‌اندازی دوباره از همان نقطه ادامه می‌یابد	دارد
تکرار درخواست یا قطع ارتباط	هر انتشار با شناسهٔ پیشنهاد ثبت می‌شود؛ تکرار، نظر تکراری نمی‌سازد	دارد
جابه‌جایی میان دو پرونده	وضعیت و مجوزها برای هر پرونده جداست	دارد

سناریوی خواسته‌شده	رفتار سامانه	آزمون خودکار
محدودیت مرحله	حداکثر ۴۰ اجرای گره در هر نوبت	—
خرابی ابزار	خارج از دامنهٔ این پروژه	—

بازبینی هر تغییر: دو سیاست هست: با پیش‌فرض `case.review = "escalations"` فقط ارجاع‌ها منتظر تأیید می‌مانند؛ با `case.review = "all"` هر پاسخ، پرسش و ارجاع پیش از انتشار به تأیید نگه‌دارنده می‌رسد. این نیاز را در نظر گرفته‌ایم: با سیاست `"all"` هر تغییر قابل مشاهده در پرونده پیش از انتشار تأیید می‌شود. فیلد required_human_review در ارزیابی مدل دربارهٔ خود مسئلهٔ کاربر است و جای این تأیید را نمی‌گیرد.

۱۳. هزینه و زمان

> روی همان ۱۵ پرونده، طراحی نهایی برای هر پرونده حدود ۰٫۰۲۴ دلار و Baseline حدود ۰٫۰۰۰۸ دلار هزینه دارد؛ تقریباً همهٔ اختلاف از توکن‌های خروجی مدل ارزیابی، یعنی استدلال پنهان آن، می‌آید.

برای هر پرونده	Baseline، ۶ chunk	طراحی پیشین	طراحی نهایی	نهایی با gpt-5-mini
فراخوانی مدل (به‌جز embedding پرسش)	۱	۳	۳	۳
توکن ورودی (میانگین)	۴,۴۴۸	۱۲,۱۸۳	۱۲,۵۹۸	۱۲,۵۹۸
توکن خروجی (میانگین)	۱۸۰	۳,۰۹۴	۳,۸۰۸	۳,۳۵۷
زمان پاسخ: میانگین / صدک ۹۵ (ثانیه)	۵٫۲ / ۷٫۱	۲۵~	۳۱٫۰ / ۲۰٫۵	۵۲ / ۳۰~
هزینه	~$ ۰٫۰۰۰۸	~$ ۰٫۰۲۱	~$ ۰٫۰۲۴	~$ ۰٫۰۰۹

جدول ۱ — scope gate در این اجراها خاموش بود؛ در سامانهٔ واقعی یک فراخوانی کوچک gpt-4o-mini می‌افزاید. زمان طراحی پیشین از اولین اجرای کامل آن است.

چرا طراحی نهایی کمی گران‌تر است: پرسش کامل هیچ هزینه‌ای ندارد (پس از پاسخ مدل اجرا می‌شود). افزایش از یادداشت نسخه است: ورودی ۳٪ بیشتر شد (متن یادداشت‌ها) و خروجی ۲۳٪ بیشتر، چون بیشتر خروجی gpt-5.4-mini استدلال پنهان است و با اطلاعات نسخه روی هر منبع، مدل بیشتر استدلال می‌کند. بخشی از این افزایش هم نوسان طبیعی طول استدلال میان اجراهاست.

- **آماده‌سازی:** embedding حدود ۶۳۶ chunk index با text-embedding-3-small، یک‌بار؛ بانک پرسش‌های doc2query حدود ۰٫۰۲ دلار برای ۱۴۶ بخش، یک‌بار و با هر تغییر مستندات؛ محک scope gate حدود ۰٫۰۱ دلار. embeddingها در کش می‌مانند و با ساخت دوبارهٔ index دوباره پرداخت نمی‌شوند.
- **داوری:** داور بیرون از سامانه به کار رفت و هزینه‌ای از بودجهٔ API تیم نداشت.
- **بودجه:** همهٔ فراخوانی‌ها، از جمله رابط وب، از یک درگاه می‌گذرند و در یک دفتر هزینه ثبت می‌شوند.

منصفانه بودن مقایسه: مزیت طراحی نهایی از دو منبع می‌آید و هر دو آشکارا گزارش شده‌اند: بودجهٔ شواهد بیشتر، که برای سنجش آن Baseline با ۸ chunk هم اجرا شد (۶ تصمیم درست)، و مدل ارزیابی قوی‌تر از همان درگاه و همان بودجه. افزایش فراخوانی به‌خودی‌خود ارزشی ندارد؛ توجیه هزینهٔ حدود ۳۰ برابری، رسیدن تصمیم‌های درست از ۵ به ۱۲ است.

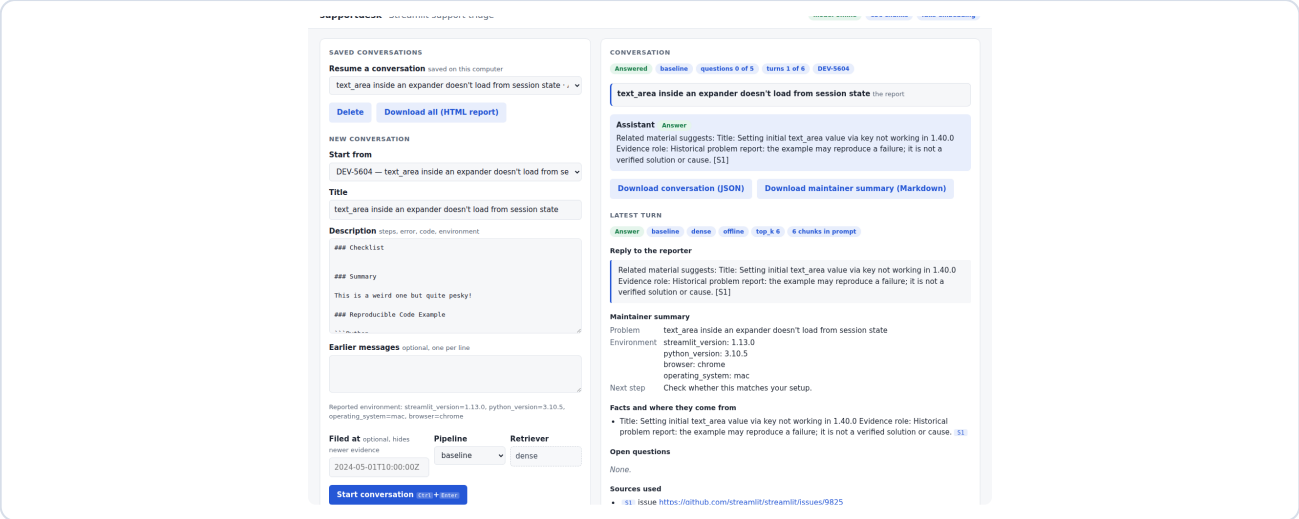
هزینهٔ هر مرحله در طراحی نهایی (برای هر پرونده، از اجراهای اندازه‌گیری‌شده):

مرحله	انجام‌دهنده	هزینه
scope gate	gpt-4o-mini	~$ ۰٫۰۰۰۱
پاک‌سازی گزارش، تطبیق doc2query، تکمیل بخش	کد	۰

مرحله	انجام‌دهنده	هزینه
جست‌وجو و reranking	embedding و gpt-4o-mini	~$ ۰٫۰۰۰۵
یادداشت نسخه، routing، پرسش کامل، پیگیری پرونده	کد	۰
ارزیابی ساختاریافته	gpt-5.4-mini	~$ ۰٫۰۲۳۷
جمع	۳ فراخوانی مدل	**~$ ۰٫۰۲۴**

۱۴. رابط وب

رابط وب هر پایپ‌لاین را روی گفت‌وگوی چندنوبتی واقعی اجرا می‌کند و همهٔ کار را روی همین رایانه ذخیره می‌کند. اجرا: `supportdesk web --mode live --pipeline advanced --port 8000` ، سپس نشانی `http://127.0.0.1:8000`.



شکل ۱۰ — یک گفت‌وگو در رابط وب: گزارش جمع‌شده، پاسخ دستیار، دریافت خروجی‌ها و جزئیات آخرین نوبت با خلاصهٔ نگهدارنده و شواهد.

قابلیت	توضیح
گفت‌وگوهای ذخیره‌شده	هر گفت‌وگو با کل تاریخچه ذخیره و از سر گرفته می‌شود؛ فهرست تنها با انتخاب کاربر عوض می‌شود.
شروع از	پرسش تازه، مثال‌ها، یا پرونده‌های توسعه و آزمون؛ تنها ورودی پرونده، هرگز فایل ارزیاب یا شواهد gold.
چندنوبتی	پس از درخواست اطلاعات، کادر پاسخ باز می‌شود و نوبت بعد با تاریخچه و شمار پرسش‌های پرسیده‌شده اجرا می‌شود؛ حداکثر ۵ پرسش و ۶ نوبت.
بازخوانی اجراهای ارزیابی	پرونده‌های هر اجرای خط فرمان، توسعه یا آزمون، بدون فراخوانی مدل به گفت‌وگو تبدیل می‌شوند و قابل ادامه‌اند.
برچسب کنار تصمیم	برای پرونده‌های ارزیابی، برچسب کنار تصمیم سامانه با نشان درست یا نادرست؛ برچسب هرگز به مدل نمی‌رسد.
شواهد و خروجی‌ها	همهٔ chunkهایی که مدل دید با متن دقیق؛ دریافت گفت‌وگو (JSON)، خلاصهٔ نگهدارنده (Markdown) و گزارش HTML.
هزینه و کش	همان درگاه، کش و دفتر هزینهٔ ارزیابی‌ها؛ پرونده‌ای که قبلاً اجرا شده از کش بازپخش می‌شود و هزینه ندارد.

تأیید انسانی پرونده‌ها (فصل ۱۲) از خط فرمان انجام می‌شود (`supportdesk case` و `supportdesk review`).

۱۵. محدودیت‌ها و گام‌های بعدی

> طراحی پیش از test انتخاب شد و test یک‌بار اجرا شد. شواهد و استناد بهبودی پایدار نشان دادند؛ سود تصمیم روی پرونده‌های تازه تکرار نشد.

۱۵-۱. محدودیت‌ها

- **اندازهٔ مجموعه:** ۱۵ پرونده کم است و نویز ممکن است تأثیرگذار باشد؛ هر تصمیم حدود ۷ درصد است.
- **برازش به dev:** بسیاری از تنظیم‌ها و هر دو اصلاح مرحلهٔ پاسخ از پرونده‌های dev آمد؛ افت روی test بخشی از همین برازش است.
- **پرسش در برابر ارجاع:** نقطهٔ ضعف اصلی در هر دو مجموعه؛ روی test طراحی نهایی هیچ پروندهٔ ارجاعی را درست نگرفت.
- **reranker:** روی test، doc2query کاندیدهای بیشتری آورد اما reranker بخش‌های gold بیشتری را حذف کرد.
- **نسخه‌ها:** مستندات تنها یک نسخه (1.65) دارد؛ reranking آگاه از نسخه و یادداشت‌های انتشارِ جدیدتر آزموده شد و بهبود نداد.
- **تأیید انسانی:** فایل‌های ارزیاب با کمک دستیار هوش مصنوعی نوشته شده‌اند و تأیید انسانی آن‌ها کامل نشده است؛ هم‌نظری دو داور (۹-۴) جای آن را نمی‌گیرد.

۱۵-۲. گام‌های بعدی

1. reranking بهتر: یک بررسی بله/خیر برای هر کاندید، یا ظرفیت بیشتر، تا کاندیدهای doc2query بخش‌های خوب را بیرون نرانند.
2. استفاده از مدل‌های مخصوص reranking (مانند Jina Reranker).
3. تشخیص پرسش از ارجاع: پیش از ارجاع، بررسی صریح اینکه آیا آزمون ساده‌ای از کاربر می‌تواند علت را جدا کند.
4. مستندات نسخه‌دار برای گزارش‌های قدیمی، با برچسب‌گذاری دوبارهٔ شواهد gold.
5. ارزیابی gpt-5-mini روی مجموعه‌ای بزرگ‌تر، با توجه به هزینهٔ یک‌سوم.